扩散生成模型的数学原理

DDPM · 噪声预测 · Score Matching · SDE 直觉桥接

教案 / 自学笔记（含推导与插图）

面向已熟悉基础概率与深度学习的读者

学习目标

1. 用直觉理解前向加噪与反向去噪如何构成生成模型；
2. 掌握闭式前向采样公式 $q(\mathbf{x}_t \mid \mathbf{x}_0)$，以及 β_t / $\bar{\alpha}_t$ 日程（schedule）的含义；
3. 理解反向过程的高斯参数化，以及为何常用 $\boldsymbol{\epsilon}_\theta$ 预测噪声；
4. 理清从变分下界（ELBO）到简化 MSE 训练目标的推导主线；
5. 能写出（伪代码级）DDPM 采样步骤，并与 score / SDE 观点建立直觉联系。

主要参考（真实文献，便于对照精读）：

[1] J. Ho, A. Jain, P. Abbeel. *Denoising Diffusion Probabilistic Models.* NeurIPS 2020.

[2] Y. Song, S. Ermon. *Generative Modeling by Estimating Gradients of the Data Distribution.* NeurIPS 2019.

[3] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, B. Poole. *Score-Based Generative Modeling through Stochastic Differential Equations.* ICLR 2021.

[4] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, S. Ganguli. *Deep Unsupervised Learning using Nonequilibrium Thermodynamics.* ICML 2015.

记号约定： $\mathbf{x}_0$ 为干净数据；$\mathbf{x}_t$ 为时刻 t 的带噪样本；$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$；$\beta_t$ 为前向噪声日程；$\alpha_t = 1 - \beta_t$；$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$（约定 $\bar{\alpha}_0 = 1$）；$\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)$ 为噪声预测网络；$\tilde{\boldsymbol{\mu}}_t$、$\tilde{\beta}_t$ 分别为（给定 $\mathbf{x}_0$ 时）真实后验的均值与方差。

一、直觉图：从清晰图像到噪声，再反向生成

扩散生成模型（Diffusion Generative Models）的核心思想非常朴素：先把数据分布通过一条预先设计好的「加噪」马尔可夫链，逐步破坏成近似标准正态；再学习一条「去噪」马尔可夫链，从纯噪声一步步还原出接近真实数据的样本。训练时我们只学反向过程的参数 θ；采样时从 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发迭代去噪得到 $\mathbf{x}_0$。

可以把前向过程想成「把一幅清晰照片慢慢糊成雪花屏」——这是固定的、不需要学习的；反向过程则是「从雪花屏里一点点恢复出一张新照片」——这才是网络要学的本领。关键技巧在于：前向加噪有闭式公式，因此训练时不必真的走完所有逐步加噪，可以直接一次采样任意时刻的 $\mathbf{x}_t$。

为什么这样做？ 为什么要分成很多小步，而不是一步从噪声变成数据?「噪声 → 数据」的整体映射极其复杂（GAN、VAE 正是试图一步学会它，因此训练困难或样本模糊）。把它拆成 T 个小步后，每一步只需去掉一点点噪声，这个局部任务简单得多，并且小步下反向转移近似为高斯（见 3.2 节），可以用简单的高斯模型加上一个去噪网络来表示。代价是采样需要多步迭代。

图0 扩散模型总览：前向加噪与反向去噪

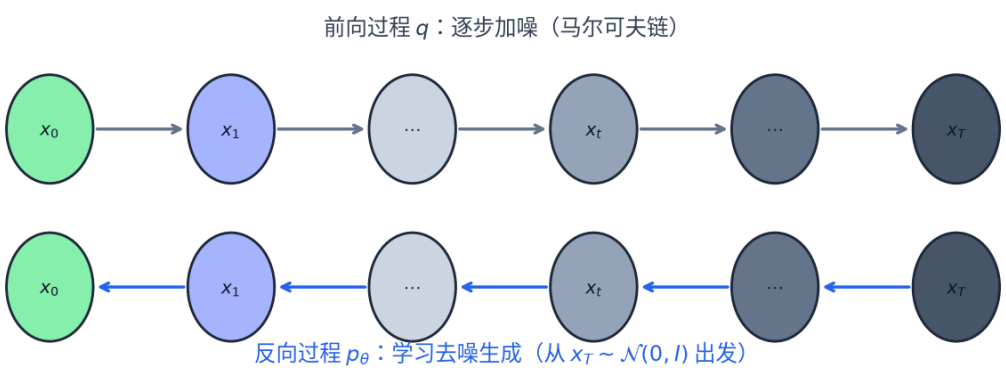


图 0　前向加噪（上）与反向去噪生成（下）总览

图 0 用颜色深浅示意噪声含量：左侧 $\mathbf{x}_0$ 偏「干净」，右侧 $\mathbf{x}_T$ 接近各向同性高斯。生成时箭头反向：从右端噪声出发，沿 p_θ 逐步走到左端数据流形附近。

图4 反向去噪生成：从纯噪声逐步回到数据分布

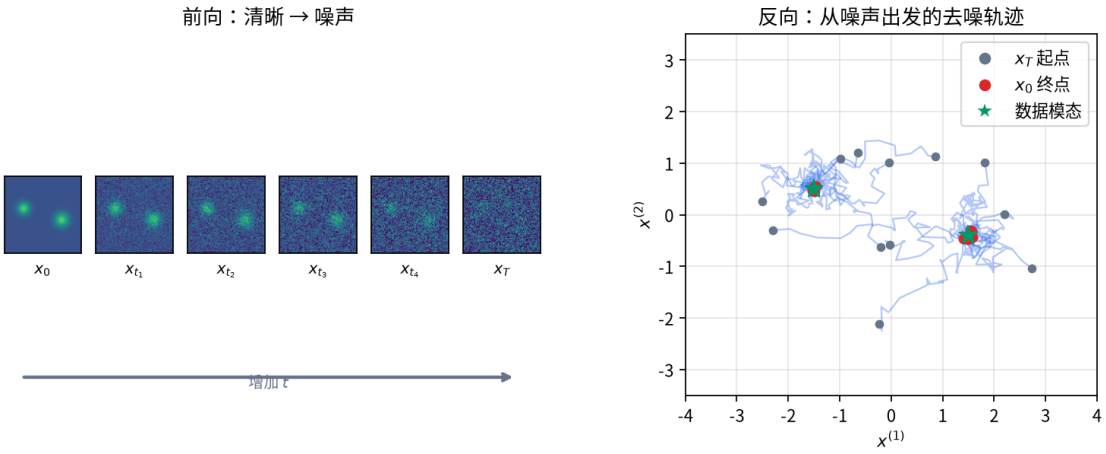


图 4　左：前向破坏结构；右：多条反向轨迹汇聚到数据模态

二、前向过程：马尔可夫链与闭式 $q(\mathbf{x}_t \mid \mathbf{x}_0)$

2.1 逐步加噪定义

给定数据 $\mathbf{x}_0 \sim q(\mathbf{x}_0)$，前向过程定义为固定的马尔可夫链：每一步对当前状态加入少量高斯噪声。

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}) = \mathcal{N}\left(\mathbf{x}_t;\ \sqrt{1-\beta_t}\,\mathbf{x}_{t-1},\ \beta_t \mathbf{I}\right), \tag{2.1}$$

$$q(\mathbf{x}_{1:T} \mid \mathbf{x}_0) = \prod_{t=1}^{T} q(\mathbf{x}_t \mid \mathbf{x}_{t-1}). \tag{2.2}$$

其中 $\beta_t \in (0,1)$ 是预先选定的方差日程（variance schedule）。β_t 很小时，每一步只轻微扰动；当 T 足够大、使得 $\bar{\alpha}_T = \prod_{t=1}^{T}(1-\beta_t) \approx 0$ 时，$\mathbf{x}_T$ 的分布会接近 $\mathcal{N}(\mathbf{0}, \mathbf{I})$，几乎与 $\mathbf{x}_0$ 无关。

为什么这样做？ 为什么均值要乘 $\sqrt{1-\beta_t}$，而不是直接 $\mathbf{x}_t = \mathbf{x}_{t-1} + \sqrt{\beta_t}\,\boldsymbol{\epsilon}_t$？ 设数据已归一化为单位方差，$\mathrm{Var}(\mathbf{x}_{t-1}) = 1$。按 (2.1)，

$$\mathrm{Var}(\mathbf{x}_t) = (1-\beta_t)\,\mathrm{Var}(\mathbf{x}_{t-1}) + \beta_t = (1-\beta_t) + \beta_t = 1,$$

方差在每一步都保持不变（variance preserving，VP）：信号被缩小的部分正好由噪声补上。若不缩放，方差会累加为 $1 + \sum_t \beta_t$ 而不断增大（这是 VE 型设计），终点就不是固定的 $\mathcal{N}(\mathbf{0}, \mathbf{I})$。VP 设计的好处：(i) 终点分布确定为 $\mathcal{N}(\mathbf{0}, \mathbf{I})$，采样起点与数据无关；(ii) 网络在所有 t 上看到的输入尺度一致，便于训练。

2.2 记号：α_t 与 $\bar{\alpha}_t$

$$\alpha_t \coloneqq 1 - \beta_t, \qquad \bar{\alpha}_t \coloneqq \prod_{s=1}^{t} \alpha_s. \tag{2.3}$$

$\bar{\alpha}_t$ 刻画了「到时刻 t 为止，原始信号还剩多少比例」（信号方差比例）。$\bar{\alpha}_t$ 随 t 单调递减：t 接近 0 时 $\bar{\alpha}_t \approx 1$（几乎全是信号），$t \to T$ 时 $\bar{\alpha}_t \to 0$（几乎全是噪声）。

2.3 闭式边缘分布（关键公式）

利用高斯分布的再生性（独立高斯之和仍为高斯），可以把多步加噪坍缩成一步。令 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，则

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}, \tag{2.4}$$

$$\text{亦即} \quad q(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}\left(\mathbf{x}_t;\ \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0,\ (1-\bar{\alpha}_t)\mathbf{I}\right). \tag{2.5}$$

推导要点（归纳法）。由 (2.1)，$\mathbf{x}_1 = \sqrt{\alpha_1}\,\mathbf{x}_0 + \sqrt{1-\alpha_1}\,\boldsymbol{\epsilon}_1$，结论对 $t=1$ 成立。假设 $\mathbf{x}_{t-1} = \sqrt{\bar{\alpha}_{t-1}}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_{t-1}}\,\tilde{\boldsymbol{\epsilon}}$，代入 $\mathbf{x}_t = \sqrt{\alpha_t}\,\mathbf{x}_{t-1} + \sqrt{1-\alpha_t}\,\boldsymbol{\epsilon}_t$：

$$\mathbf{x}_t = \sqrt{\alpha_t \bar{\alpha}_{t-1}}\,\mathbf{x}_0 + \underbrace{\sqrt{\alpha_t(1-\bar{\alpha}_{t-1})}\,\tilde{\boldsymbol{\epsilon}} + \sqrt{1-\alpha_t}\,\boldsymbol{\epsilon}_t}_{\sim\,\mathcal{N}(\mathbf{0},\ [\alpha_t(1-\bar{\alpha}_{t-1})+(1-\alpha_t)]\mathbf{I})}. \tag{2.6}$$

合并的噪声方差为 $\alpha_t(1-\bar{\alpha}_{t-1}) + (1-\alpha_t) = 1 - \alpha_t\bar{\alpha}_{t-1} = 1 - \bar{\alpha}_t$，且 $\alpha_t\bar{\alpha}_{t-1} = \bar{\alpha}_t$，即得 (2.4)。（「两个独立高斯噪声合并为一个」的引理与逐行推导见 2.4 节。）这一闭式使训练时可对任意 t 直接构造 $\mathbf{x}_t$，无需模拟整条链。

为什么这样做？ 为什么闭式 $q(\mathbf{x}_t \mid \mathbf{x}_0)$ 对训练如此重要？ 训练目标是对 $t = 1, \dots, T$ 的各项求和（第四节）。有了闭式，就可以随机抽一个 $t \sim \mathrm{Uniform}\{1, \dots, T\}$，一步得到 $\mathbf{x}_t$，用这一项的梯度作为整体求和的无偏估计（$\sum_t L_t = T \cdot \mathbb{E}_t[L_t]$）。每个训练样本的代价是 $O(1)$ 次网络前向，而不是 $O(T)$；同一批次中不同样本取不同 t，网络同时学会所有噪声水平。

2.4 重参数化技巧（reparameterization trick）详解

上面的闭式 (2.4) 把「$\mathbf{x}_t$ 服从某个高斯」写成了「$\mathbf{x}_t$ 是 $\mathbf{x}_0$ 与一个标准噪声 $\boldsymbol{\epsilon}$ 的确定性函数」。这种写法就是**重参数化技巧**。它在 DDPM 中出现了至少四次（前向一步、闭式推导、训练、采样），下面把它单独讲透。

(1) 它是什么：位置-尺度变换。 任何各向同性高斯都可以由标准高斯经平移、缩放得到：

$$\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2 \mathbf{I}) \quad \Longleftrightarrow \quad \mathbf{z} = \boldsymbol{\mu} + \sigma\, \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \tag{2.7}$$

证明一（矩 + 仿射不变性）。高斯向量经仿射变换仍是高斯，因此只需核对均值与协方差：

$$\mathbb{E}[\mathbf{z}] = \boldsymbol{\mu} + \sigma\, \mathbb{E}[\boldsymbol{\epsilon}] = \boldsymbol{\mu},$$
$$\mathrm{Cov}[\mathbf{z}] = \mathbb{E}\big[(\mathbf{z}-\boldsymbol{\mu})(\mathbf{z}-\boldsymbol{\mu})^\top\big] = \sigma^2\, \mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}^\top] = \sigma^2 \mathbf{I}.$$

证明二（变量替换）。$\boldsymbol{\epsilon} = (\mathbf{z}-\boldsymbol{\mu})/\sigma$，雅可比行列式 $\left|\det \frac{\partial \boldsymbol{\epsilon}}{\partial \mathbf{z}}\right| = \sigma^{-d}$（$d$ 为维数），故

$$p_{\mathbf{z}}(\mathbf{z}) = p_{\boldsymbol{\epsilon}}\Big(\frac{\mathbf{z}-\boldsymbol{\mu}}{\sigma}\Big)\, \sigma^{-d} = \frac{1}{(2\pi)^{d/2}\sigma^d} \exp\Big(-\frac{\|\mathbf{z}-\boldsymbol{\mu}\|^2}{2\sigma^2}\Big) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}, \sigma^2\mathbf{I}). \tag{2.8}$$

（一般协方差 $\boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}^\top$ 时写成 $\mathbf{z} = \boldsymbol{\mu} + \mathbf{L}\boldsymbol{\epsilon}$。）

为什么这样做？ **这一改写的本质：把「随机性」和「参数 / 输入」分开。**左边「从 $\mathcal{N}(\boldsymbol{\mu}, \sigma^2\mathbf{I})$ 中抽样」是一个依赖参数的随机操作；右边的随机性全部集中在*不含任何参数的* $\boldsymbol{\epsilon}$ 上，而 $\boldsymbol{\mu}, \sigma$ 只通过一个普通的、可微的算术式 $\boldsymbol{\mu} + \sigma\boldsymbol{\epsilon}$ 进入。于是：采样变成「先抽固定分布的噪声，再做确定性计算」；而且只要记住所用的 $\boldsymbol{\epsilon}$，就知道样本是「怎么来的」。**为什么系数是 σ 而不是 σ^2？** 乘在 $\boldsymbol{\epsilon}$ 前面的是*标准差*：$\mathrm{Var}(\sigma\boldsymbol{\epsilon}) = \sigma^2$。所以方差为 β_t 的噪声写成 $\sqrt{\beta_t}\,\boldsymbol{\epsilon}$，方差为 $1-\bar{\alpha}_t$ 的写成 $\sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}$——公式里那些根号都来源于此。

(2) 它为什么重要：来自 VAE 的梯度问题。 Kingma & Welling（2014，VAE）与 Rezende et al.（2014）提出这个技巧，是为了计算 $\nabla_\phi\, \mathbb{E}_{\mathbf{z}\sim q_\phi}[f(\mathbf{z})]$——期望所对的分布本身依赖参数 ϕ，而「抽样」这一步对 ϕ 不可微（图 6(a)）。有两种估计方式：

$$\text{得分函数 / REINFORCE:} \quad \nabla_\phi\, \mathbb{E}_{q_\phi}[f(\mathbf{z})] = \int f(\mathbf{z})\, \nabla_\phi q_\phi(\mathbf{z})\, \mathrm{d}\mathbf{z} = \mathbb{E}_{q_\phi}\big[f(\mathbf{z})\, \nabla_\phi \log q_\phi(\mathbf{z})\big], \tag{2.9}$$

$$\text{重参数化 / 路径导数:} \quad \nabla_\phi\, \mathbb{E}_{q_\phi}[f(\mathbf{z})] = \nabla_\phi\, \mathbb{E}_{\boldsymbol{\epsilon}}\big[f(\boldsymbol{\mu}_\phi + \sigma_\phi\boldsymbol{\epsilon})\big] = \mathbb{E}_{\boldsymbol{\epsilon}}\Big[\nabla_{\mathbf{z}} f(\mathbf{z})^\top \Big(\frac{\partial \boldsymbol{\mu}_\phi}{\partial \phi} + \boldsymbol{\epsilon}\, \frac{\partial \sigma_\phi}{\partial \phi}\Big)\Big]. \tag{2.10}$$

(2.9) 用到恒等式 $\nabla_\phi q_\phi = q_\phi \nabla_\phi \log q_\phi$；(2.10) 中 $\boldsymbol{\epsilon}$ 的分布与 ϕ 无关，梯度可直接移进期望（图 6(b)），其中 $\mathbf{z} = \boldsymbol{\mu}_\phi + \sigma_\phi\boldsymbol{\epsilon}$。

一个可以手算的例子。$z \sim \mathcal{N}(\mu, 1)$，$f(z) = z^2$，对 μ 求导。真值：$\mathbb{E}[z^2] = \mu^2 + 1$，梯度 $= 2\mu$。

- 路径导数：单样本估计 $2z = 2(\mu+\epsilon)$，均值 2μ，方差 $\mathrm{Var}(2\epsilon) = 4$。
- REINFORCE：$\nabla_\mu \log q = z - \mu = \epsilon$，单样本估计 $(\mu+\epsilon)^2\epsilon$，均值 $\mathbb{E}[\mu^2\epsilon + 2\mu\epsilon^2 + \epsilon^3] = 2\mu$；利用 $\mathbb{E}[\epsilon^2]=1, \mathbb{E}[\epsilon^4]=3, \mathbb{E}[\epsilon^6]=15$，可得二阶矩 $\mathbb{E}[(\mu+\epsilon)^4\epsilon^2] = \mu^4 + 18\mu^2 + 15$，方差 $= \mu^4 + 14\mu^2 + 15$（$\mu=0$ 时为 15，$\mu=2$ 时为 87）。

两者都无偏，但路径导数利用了 f 的梯度信息，方差通常小得多；REINFORCE 只用到 f 的取值，方差随 $|f|$ 增大，需要基线（baseline）等降方差技巧。

为什么这样做？ **为什么在 VAE 里非用不可？**编码器输出 $\boldsymbol{\mu}_\phi(\mathbf{x}), \sigma_\phi(\mathbf{x})$，解码器的重构误差要对编码器参数 ϕ 求导，而中间隔着一个「采样 $\mathbf{z}$」。重参数化把这个采样节点换成可微的 $\boldsymbol{\mu}_\phi + \sigma_\phi\boldsymbol{\epsilon}$，反向传播即可一路走通。这要求分布属于*位置-尺度族*（如高斯、拉普拉斯、逻辑斯谛）或至少有可微的采样变换；离散分布（如类别分布）不能直接这样做（需 Gumbel-Softmax

等松弛）。

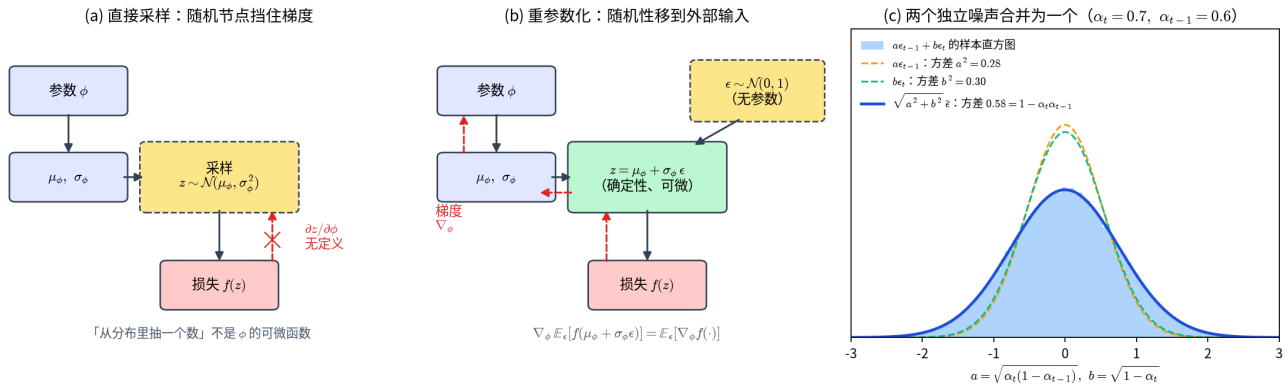


图 6　重参数化技巧。(a) 直接从 $\mathcal{N}(\mu_\phi,\sigma_\phi^2)$ 采样：采样节点对 ϕ 不可微，梯度传不回去；(b) 写成 $z=\mu_\phi+\sigma_\phi\epsilon$：随机性来自无参数的外部输入 ϵ，梯度沿确定性路径回传；(c) 两个独立高斯噪声之和仍是高斯，方差相加：$a^2+b^2=1-\alpha_t\alpha_{t-1}$（直方图为 2×10^5 个样本）。

(3a) 扩散中的用法一：前向单步。　定义 (2.1) 用重参数化写就是

$$\mathbf{x}_t=\sqrt{\alpha_t}\,\mathbf{x}_{t-1}+\sqrt{\beta_t}\,\boldsymbol{\epsilon}_t,\qquad \boldsymbol{\epsilon}_t\sim\mathcal{N}(\mathbf{0},\mathbf{I}),\ \ \boldsymbol{\epsilon}_1,\dots,\boldsymbol{\epsilon}_T\ \text{相互独立且与}\ \mathbf{x}_0\ \text{独立.}\tag{2.11}$$

(3b) 用法二：推导闭式——合并独立高斯噪声（DDPM 里最常说的「重参数化技巧」）。　**引理。**若 $\boldsymbol{\epsilon}_1,\boldsymbol{\epsilon}_2\sim\mathcal{N}(\mathbf{0},\mathbf{I})$ 独立，则 $a\boldsymbol{\epsilon}_1+b\boldsymbol{\epsilon}_2\sim\mathcal{N}\big(\mathbf{0},(a^2+b^2)\mathbf{I}\big)$，即可写成 $\sqrt{a^2+b^2}\,\bar{\boldsymbol{\epsilon}}$，$\bar{\boldsymbol{\epsilon}}\sim\mathcal{N}(\mathbf{0},\mathbf{I})$。*证明：*独立随机变量之和的特征函数是乘积，$\mathbb{E}[e^{i\mathbf{u}^\top(a\boldsymbol{\epsilon}_1+b\boldsymbol{\epsilon}_2)}]=e^{-a^2\|\mathbf{u}\|^2/2}\,e^{-b^2\|\mathbf{u}\|^2/2}=e^{-(a^2+b^2)\|\mathbf{u}\|^2/2}$，正是 $\mathcal{N}(\mathbf{0},(a^2+b^2)\mathbf{I})$ 的特征函数。（直观：独立 $\Rightarrow$ 方差相加，均值仍为 $\mathbf{0}$。注意相加的是*方差* a^2,b^2，而不是系数 a,b。）

两步合并，逐行计算。从 $\mathbf{x}_{t-2}$ 出发连续用两次 (2.11)：

$$\begin{aligned}\mathbf{x}_{t-1}&=\sqrt{\alpha_{t-1}}\,\mathbf{x}_{t-2}+\sqrt{1-\alpha_{t-1}}\,\boldsymbol{\epsilon}_{t-1},\\ \mathbf{x}_t&=\sqrt{\alpha_t}\,\mathbf{x}_{t-1}+\sqrt{1-\alpha_t}\,\boldsymbol{\epsilon}_t\\ &=\sqrt{\alpha_t}\Big(\sqrt{\alpha_{t-1}}\,\mathbf{x}_{t-2}+\sqrt{1-\alpha_{t-1}}\,\boldsymbol{\epsilon}_{t-1}\Big)+\sqrt{1-\alpha_t}\,\boldsymbol{\epsilon}_t\\ &=\sqrt{\alpha_t\alpha_{t-1}}\,\mathbf{x}_{t-2}+\underbrace{\sqrt{\alpha_t(1-\alpha_{t-1})}}_{a}\,\boldsymbol{\epsilon}_{t-1}+\underbrace{\sqrt{1-\alpha_t}}_{b}\,\boldsymbol{\epsilon}_t.\end{aligned}\tag{2.12}$$

两项噪声独立，由引理，方差相加：

$$a^2+b^2=\alpha_t(1-\alpha_{t-1})+(1-\alpha_t)=\alpha_t-\alpha_t\alpha_{t-1}+1-\alpha_t=1-\alpha_t\alpha_{t-1},\tag{2.13}$$

所以

$$\mathbf{x}_t=\sqrt{\alpha_t\alpha_{t-1}}\,\mathbf{x}_{t-2}+\sqrt{1-\alpha_t\alpha_{t-1}}\,\bar{\boldsymbol{\epsilon}}_{t-2},\qquad \bar{\boldsymbol{\epsilon}}_{t-2}\sim\mathcal{N}(\mathbf{0},\mathbf{I}).\tag{2.14}$$

模式：信号系数的平方 $\alpha_t\alpha_{t-1}$ 与噪声方差 $1-\alpha_t\alpha_{t-1}$ 之和恒为 1。继续往回合并（即 2.3 节的归纳法）得到 $\mathbf{x}_t=\sqrt{\bar\alpha_t}\,\mathbf{x}_0+\sqrt{1-\bar\alpha_t}\,\boldsymbol{\epsilon}$。

不用归纳、一次性展开的验证。把 (2.11) 从 $s=t$ 一路代回到 $s=1$：

$$\mathbf{x}_t=\sqrt{\bar\alpha_t}\,\mathbf{x}_0+\sum_{s=1}^{t}\sqrt{\frac{\bar\alpha_t}{\bar\alpha_s}\,\beta_s}\,\boldsymbol{\epsilon}_s,\tag{2.15}$$

（$\boldsymbol{\epsilon}_s$ 前的系数 $=\sqrt{\beta_s}\times\sqrt{\alpha_{s+1}\cdots\alpha_t}$），噪声总方差为望远镜求和：

$$\sum_{s=1}^{t}\frac{\bar\alpha_t}{\bar\alpha_s}(1-\alpha_s)=\sum_{s=1}^{t}\left(\frac{\bar\alpha_t}{\bar\alpha_s}-\frac{\bar\alpha_t}{\bar\alpha_{s-1}}\right)=\frac{\bar\alpha_t}{\bar\alpha_t}-\frac{\bar\alpha_t}{\bar\alpha_0}=1-\bar\alpha_t,\tag{2.16}$$

（用到 $\bar\alpha_s=\alpha_s\bar\alpha_{s-1}$ 与 $\bar\alpha_0=1$），与 (2.4) 一致。

(3c) 用法三：训练。 算法 1 中每次抽 t，$\boldsymbol{\epsilon}$，一步构造 $\mathbf{x}_t = \sqrt{\bar\alpha_t}\,\mathbf{x}_0 + \sqrt{1-\bar\alpha_t}\,\boldsymbol{\epsilon}$，网络输入是 $(\mathbf{x}_0, \boldsymbol{\epsilon})$ 的确定性可微函数，损失为 $\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\|^2$。注意：

$$\nabla_\theta\, \mathbb{E}_{t,\mathbf{x}_0,\boldsymbol{\epsilon}}\Big[\big\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta\big(\sqrt{\bar\alpha_t}\,\mathbf{x}_0 + \sqrt{1-\bar\alpha_t}\,\boldsymbol{\epsilon},\ t\big)\big\|^2\Big] = \mathbb{E}_{t,\mathbf{x}_0,\boldsymbol{\epsilon}}\Big[\nabla_\theta\big\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\cdots)\big\|^2\Big]. \tag{2.17}$$

这里求导只针对网络参数 θ；前向过程没有可学参数，期望所对的分布本来就与 θ 无关。所以在标准 DDPM 中，重参数化的作用不是像 VAE 那样「让梯度穿过采样节点」，而是：

(i) $O(1)$ **采样 $\mathbf{x}_t$：**任意 t 一步到位，无需模拟 t 步（2.3 节为什么框）；

(ii) **给出回归标签：**构造 $\mathbf{x}_t$ 所用的那个 $\boldsymbol{\epsilon}$ 被记录下来，正好作为监督学习的目标——「已知答案的去噪练习题」；

(iii) **在 $\mathbf{x}_0$ 与 $\boldsymbol{\epsilon}$ 之间换算：**给定 $\mathbf{x}_t$，由 $\mathbf{x}_0 = (\mathbf{x}_t - \sqrt{1-\bar\alpha_t}\,\boldsymbol{\epsilon})/\sqrt{\bar\alpha_t}$ 可以把 $\tilde{\boldsymbol{\mu}}_t$ 改写成 $\boldsymbol{\epsilon}$ 形式（3.5 节式 (3.42)），也是 4.3 节把 KL 化为噪声 MSE 的关键一步。

（只有当前向过程本身含可学参数时——例如 Variational Diffusion Models（Kingma et al., NeurIPS 2021）学习噪声日程——梯度才需要像 VAE 那样穿过 $\mathbf{x}_t$ 的重参数化路径。）

(3d) 用法四：采样。 算法 2 中的 $\mathbf{x}_{t-1} = \boldsymbol{\mu}_\theta(\mathbf{x}_t, t) + \sigma_t \mathbf{z}$，$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，就是对反向高斯 $p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t) = \mathcal{N}(\boldsymbol{\mu}_\theta, \sigma_t^2\mathbf{I})$ 的重参数化采样：先抽无参数噪声 $\mathbf{z}$，再做确定性的平移与缩放。

澄清：DDPM 文献里的「重参数化」有两层意思，别混淆。

	A. 采样重参数化	B. 模型参数化（parameterization）
是什么	把随机变量写成「确定性函数 + 无参数噪声」：$\mathbf{z} = \boldsymbol{\mu} + \sigma\boldsymbol{\epsilon}$	选择网络输出什么量：$\boldsymbol{\epsilon}$、$\mathbf{x}_0$ 还是 $\tilde{\boldsymbol{\mu}}$（或 v、得分）
出现位置	前向单步、闭式合并、构造 $\mathbf{x}_t$、祖先采样	3.5–3.6 节的 $\boldsymbol{\mu}_\theta$ 写法 (3.43)；4.3 节 L_{simple}
改变了什么	计算方式；分布不变	网络的学习目标与优化难度；模型族不变（可互相换算）

Ho et al.（2020）说「$\boldsymbol{\epsilon}$-prediction parameterization」指的是 B；但 B 之所以可行，正是借助了 A 给出的关系 $\mathbf{x}_t = \mathbf{x}_t(\mathbf{x}_0, \boldsymbol{\epsilon})$。

常见坑。

1. **每一步的噪声必须是新抽的、相互独立的。**$\boldsymbol{\epsilon}_1, \ldots, \boldsymbol{\epsilon}_T$ 若重复使用同一个，噪声就不再独立，引理不成立（方差变成 $(a+b)^2$ 而非 a^2+b^2）。采样时每步的 $\mathbf{z}$ 也必须重新抽取。
2. **合并后的 $\bar\epsilon$ 是一个新变量。**$\bar\epsilon = (a\boldsymbol{\epsilon}_{t-1} + b\boldsymbol{\epsilon}_t)/\sqrt{a^2+b^2}$ 与 $\boldsymbol{\epsilon}_{t-1}$、$\boldsymbol{\epsilon}_t$ 都相关，但不等于其中任何一个。闭式 (2.4) 中的 $\boldsymbol{\epsilon}$ 是「把 $1 \ldots t$ 步所有噪声合并成的那一个」，训练时直接抽它即可，不必（也不能）还原出各步的 $\boldsymbol{\epsilon}_s$。
3. **系数是标准差，不是方差。**方差为 β_t 的噪声写 $\sqrt{\beta_t}\,\boldsymbol{\epsilon}$；合并时把系数平方后相加再开根号。
4. **需要位置-尺度族（或可微采样变换）。**高斯天然满足；离散或其他分布不能照搬 $\boldsymbol{\mu} + \sigma\boldsymbol{\epsilon}$。
5. **引理要求独立。**$\mathbf{x}_{t-1}$ 中的噪声只依赖 $\boldsymbol{\epsilon}_1, \ldots, \boldsymbol{\epsilon}_{t-1}$，与新的 $\boldsymbol{\epsilon}_t$ 独立，所以每次合并都合法。

2.5 β 日程的直觉

经典 DDPM 常用线性日程：β_t 从 $\beta_1 = 10^{-4}$ 线性增至 $\beta_T = 0.02$（$T = 1000$）。也有 cosine schedule（Nichol & Dhariwal, 2021）使中间时段信号衰减更平滑。选择原则：既要让 $\mathbf{x}_T$ 充分接近标准正态，又要避免过早把信号毁掉，导致后期去噪过难。

图1 前向过程：加噪强度随 t 变化

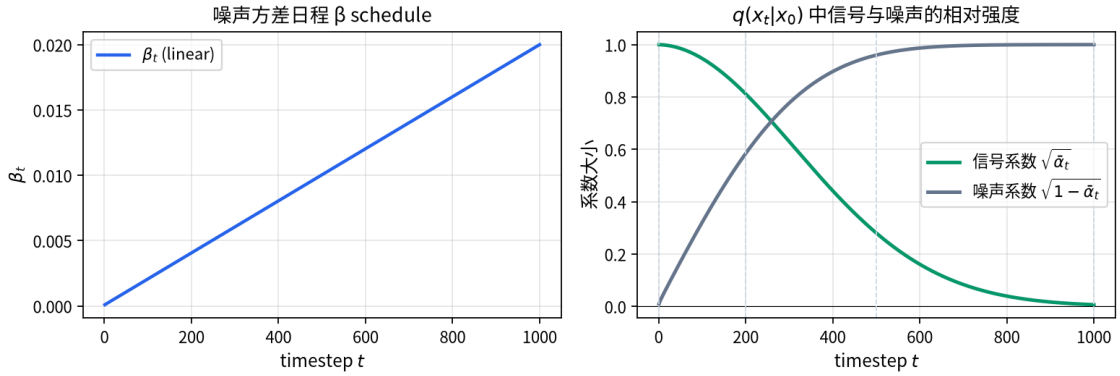


图 1　左：线性 β_t；右：$\sqrt{\bar{\alpha}_t}$（信号系数）与 $\sqrt{1-\bar{\alpha}_t}$（噪声系数）随 t 的变化

图2 一维混合分布在前向加噪下逐渐变为高斯

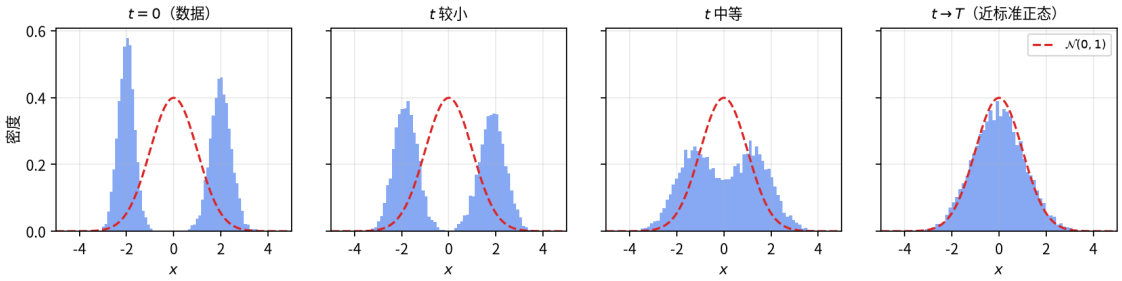


图 2　一维双峰分布在前向加噪下逐渐「高斯化」

图 2 直观说明：无论原始数据多么多峰、复杂，足够强的各向同性高斯噪声会抹平结构，使分布逼近 $\mathcal{N}(\mathbf{0}, \mathbf{I})$。这也解释了为何可以从「与数据无关」的先验噪声开始生成。

三、反向过程：从贝叶斯公式一步步推导

本节目标：搞清楚「反向一步」应该长什么样，并把它写成网络可以学习的形式。路线是

$$\underbrace{q(\mathbf{x}_{t-1}\mid\mathbf{x}_t)}_{\text{真正想要，但算不出}}\ \longrightarrow\ \underbrace{q(\mathbf{x}_{t-1}\mid\mathbf{x}_t,\mathbf{x}_0)}_{\text{加条件 }\mathbf{x}_0\text{ 后可精确计算}}\ \longrightarrow\ \underbrace{p_\theta(\mathbf{x}_{t-1}\mid\mathbf{x}_t)}_{\text{用网络去逼近}}.$$

3.1 真实反向转移为什么算不出来

由贝叶斯公式，真实的反向转移为

$$q(\mathbf{x}_{t-1}\mid\mathbf{x}_t)=\frac{q(\mathbf{x}_t\mid\mathbf{x}_{t-1})\,q(\mathbf{x}_{t-1})}{q(\mathbf{x}_t)},\qquad q(\mathbf{x}_{t-1})=\int q(\mathbf{x}_{t-1}\mid\mathbf{x}_0)\,q(\mathbf{x}_0)\,\mathrm{d}\mathbf{x}_0. \tag{3.1}$$

为什么这样做？ **为什么 $q(\mathbf{x}_{t-1}\mid\mathbf{x}_t)$ 不可直接用？**分子里的 $q(\mathbf{x}_{t-1})$、分母里的 $q(\mathbf{x}_t)$ 都是带噪数据的边缘分布，需要对未知的数据分布 $q(\mathbf{x}_0)$ 积分。我们手里只有有限个样本，没有 $q(\mathbf{x}_0)$ 的解析式；即便用经验分布代替，结果也只是在训练样本之间「插值 / 记忆」，无法泛化出新样本。
为什么加上条件 $\mathbf{x}_0$ 就可算？一旦把 $\mathbf{x}_0$ 当作已知，式中出现的所有分布——$q(\mathbf{x}_t\mid\mathbf{x}_{t-1})$、$q(\mathbf{x}_{t-1}\mid\mathbf{x}_0)$、$q(\mathbf{x}_t\mid\mathbf{x}_0)$——都是我们自己设计的高斯（式 (2.1)、(2.5)），对未知 $q(\mathbf{x}_0)$ 的依赖消失了。训练时 $\mathbf{x}_0$ 恰好是已知的（就是那张训练图），所以可以用它构造「标准答案」。

3.2 为什么可以把反向一步建模为高斯

3.4 节将证明：给定 $\mathbf{x}_0$ 时后验 $q(\mathbf{x}_{t-1}\mid\mathbf{x}_t,\mathbf{x}_0)$ 精确是高斯。但网络 $p_\theta(\mathbf{x}_{t-1}\mid\mathbf{x}_t)$ 看不到 $\mathbf{x}_0$，它真正要逼近的是不带 $\mathbf{x}_0$ 的真实反向转移 $q(\mathbf{x}_{t-1}\mid\mathbf{x}_t)$——这是许多高斯按 $q(\mathbf{x}_0\mid\mathbf{x}_t)$ 加权的混合，一般不是高斯。那凭什么还能用一个高斯去建模它？下面分五步说明：答案是「步子足够小」。

第 1 步：从贝叶斯公式出发，一步步写出对数后验。 记 $q_{t-1}(\cdot)$ 为 $\mathbf{x}_{t-1}$ 的真实边缘分布（未知、一般非高斯，例如多峰），$q_t(\cdot)$ 同理。下面分 5 个小步，从贝叶斯公式走到「平方差」形式。

(1a) 贝叶斯公式，并去掉与 $\mathbf{x}_{t-1}$ 无关的分母。由 (3.1)：

$$q(\mathbf{x}_{t-1}\mid\mathbf{x}_t)=\frac{q(\mathbf{x}_t\mid\mathbf{x}_{t-1})\,q_{t-1}(\mathbf{x}_{t-1})}{q_t(\mathbf{x}_t)}\ \propto\ q(\mathbf{x}_t\mid\mathbf{x}_{t-1})\,q_{t-1}(\mathbf{x}_{t-1}). \tag{3.2}$$

为什么可以写 $\propto$？我们关心的是「$\mathbf{x}_{t-1}$ 的分布长什么样」，$\mathbf{x}_t$ 是给定的观测。分母 $q_t(\mathbf{x}_t)$ 只依赖 $\mathbf{x}_t$，对 $\mathbf{x}_{t-1}$ 来说是一个常数。「$\propto$」意思是「两边只差一个与 $\mathbf{x}_{t-1}$ 无关的正因子」。这个因子不需要算：任何概率密度都必须积分为 1，最后只要把形状确定下来，归一化常数会被自动补齐（例如一旦认出是高斯，常数就是 $(2\pi s)^{-d/2}$）。

(1b) 写出前向转移的密度——平方差就是从这里来的。回忆 d 维高斯密度的一般公式：

$$\mathcal{N}(\mathbf{y};\mathbf{m},\mathbf{\Sigma})=\frac{1}{(2\pi)^{d/2}\,|\mathbf{\Sigma}|^{1/2}}\exp\Big(-\frac{1}{2}(\mathbf{y}-\mathbf{m})^\top\mathbf{\Sigma}^{-1}(\mathbf{y}-\mathbf{m})\Big). \tag{3.3}$$

当协方差各向同性 $\mathbf{\Sigma}=s\mathbf{I}$ 时，$\mathbf{\Sigma}^{-1}=\frac{1}{s}\mathbf{I}$、$|\mathbf{\Sigma}|=s^d$，二次型化为平方范数：

$$(\mathbf{y}-\mathbf{m})^\top(s\mathbf{I})^{-1}(\mathbf{y}-\mathbf{m})=\frac{1}{s}(\mathbf{y}-\mathbf{m})^\top(\mathbf{y}-\mathbf{m})=\frac{\|\mathbf{y}-\mathbf{m}\|^2}{s},$$
$$\mathcal{N}(\mathbf{y};\mathbf{m},s\mathbf{I})=(2\pi s)^{-d/2}\exp\Big(-\frac{\|\mathbf{y}-\mathbf{m}\|^2}{2s}\Big). \tag{3.4}$$

前向转移 (2.1) 是 $\mathbf{y}=\mathbf{x}_t$、$\mathbf{m}=\sqrt{\alpha_t}\,\mathbf{x}_{t-1}$、$s=\beta_t$ 的情形，所以

$$q(\mathbf{x}_t\mid\mathbf{x}_{t-1})=\mathcal{N}\big(\mathbf{x}_t;\ \sqrt{\alpha_t}\,\mathbf{x}_{t-1},\ \beta_t\mathbf{I}\big)=(2\pi\beta_t)^{-d/2}\exp\Big(-\frac{\|\mathbf{x}_t-\sqrt{\alpha_t}\,\mathbf{x}_{t-1}\|^2}{2\beta_t}\Big). \tag{3.5}$$

这就是「平方差」的来源：它不是凭空出现的，而是高斯密度指数里的 $\|$变量 $-$ 均值$\|^2$；这里「变量」是 $\mathbf{x}_t$，「均值」是 $\sqrt{\alpha_t}\,\mathbf{x}_{t-1}$。注意前面的 $(2\pi\beta_t)^{-d/2}$ 不含 $\mathbf{x}_{t-1}$。

(1c) 代入 (3.2)。

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t) \;\propto\; \exp\Big(-\frac{\|\mathbf{x}_t - \sqrt{\alpha_t}\,\mathbf{x}_{t-1}\|^2}{2\beta_t}\Big) \cdot q_{t-1}(\mathbf{x}_{t-1}), \tag{3.6}$$

其中常数 $(2\pi\beta_t)^{-d/2}$ 已并入「$\propto$」。

(1d) 取对数。对 (3.6) 两边取 log：

$$\log q(\mathbf{x}_{t-1} \mid \mathbf{x}_t) = -\frac{\|\mathbf{x}_t - \sqrt{\alpha_t}\,\mathbf{x}_{t-1}\|^2}{2\beta_t} + \log q_{t-1}(\mathbf{x}_{t-1}) + \text{const}, \tag{3.7}$$

const 收集了所有与 $\mathbf{x}_{t-1}$ 无关的项（$-\log q_t(\mathbf{x}_t)$、$-\frac{d}{2}\log(2\pi\beta_t)$）。为什么取对数？(i) 乘积变成求和，两个因子可以分开分析；(ii) 高斯的 $\exp(\cdot)$ 被去掉，指数部分直接变成一个二次函数，便于后面配方、比较；(iii) 乘性常数变成加性常数，可以统一扔进 const。

(1e) 把平方差改写成「以 $\mathbf{x}_{t-1}$ 为变量」的形式。在 (3.5) 里，变量是 $\mathbf{x}_t$、中心是 $\sqrt{\alpha_t}\mathbf{x}_{t-1}$；但现在我们要研究的变量是 $\mathbf{x}_{t-1}$，$\mathbf{x}_t$ 是已知的。为了读出「作为 $\mathbf{x}_{t-1}$ 的函数，它的中心和宽度是多少」，要把它整理成「$\mathbf{x}_{t-1}-$ 中心」的形式。从括号里提出 $-\sqrt{\alpha_t}$：

$$\mathbf{x}_t - \sqrt{\alpha_t}\,\mathbf{x}_{t-1} = -\sqrt{\alpha_t}\Big(\mathbf{x}_{t-1} - \frac{\mathbf{x}_t}{\sqrt{\alpha_t}}\Big) = -\sqrt{\alpha_t}\,(\mathbf{x}_{t-1} - \mathbf{m}_t), \qquad \mathbf{m}_t := \frac{\mathbf{x}_t}{\sqrt{\alpha_t}}, \tag{3.8}$$

再利用 $\|c\,\mathbf{v}\|^2 = c^2\|\mathbf{v}\|^2$（这里 $c^2 = (-\sqrt{\alpha_t})^2 = \alpha_t$）：

$$\|\mathbf{x}_t - \sqrt{\alpha_t}\,\mathbf{x}_{t-1}\|^2 = \alpha_t \left\|\mathbf{x}_{t-1} - \frac{\mathbf{x}_t}{\sqrt{\alpha_t}}\right\|^2 = \alpha_t\,\|\mathbf{x}_{t-1} - \mathbf{m}_t\|^2. \tag{3.9}$$

于是似然因子作为 $\mathbf{x}_{t-1}$ 的函数可以读出中心与宽度：

$$\exp\Big(-\frac{\alpha_t\,\|\mathbf{x}_{t-1} - \mathbf{m}_t\|^2}{2\beta_t}\Big) = \exp\Big(-\frac{\|\mathbf{x}_{t-1} - \mathbf{m}_t\|^2}{2\,(\beta_t/\alpha_t)}\Big), \tag{3.10}$$

与 (3.4) 对照：中心 $\mathbf{m}_t = \mathbf{x}_t/\sqrt{\alpha_t}$，方差 β_t/α_t，即每个坐标宽度（标准差）$\sqrt{\beta_t/\alpha_t} \approx \sqrt{\beta_t}$。（注意：它作为 $\mathbf{x}_{t-1}$ 的函数只是一个未归一化的高斯形状，并不是 $\mathbf{x}_{t-1}$ 的概率密度——$q(\mathbf{x}_t \mid \mathbf{x}_{t-1})$ 是 $\mathbf{x}_t$ 的密度，对 $\mathbf{x}_{t-1}$ 积分一般不等于 1。这不影响我们读出「形状」。）

把 (3.9) 代回 (3.7)，得到（const 表示与 $\mathbf{x}_{t-1}$ 无关的项）

$$\log q(\mathbf{x}_{t-1} \mid \mathbf{x}_t) = \underbrace{-\frac{\alpha_t}{2\beta_t}\,\|\mathbf{x}_{t-1} - \mathbf{m}_t\|^2}_{\text{似然项：已知、精确二次}} + \underbrace{\log q_{t-1}(\mathbf{x}_{t-1})}_{\text{先验项：未知、非二次}} + \text{const}. \tag{3.11}$$

这一步在做什么？ **链条：**贝叶斯（分母与 $\mathbf{x}_{t-1}$ 无关 $\Rightarrow\propto$）(3.2) $\rightarrow$ 代入已知的高斯转移密度，指数里出现平方差 (3.5) $\rightarrow$ 取对数，乘积变和、常数并入 const (3.7) $\rightarrow$ 把平方差改写成以 $\mathbf{x}_{t-1}$ 为变量、中心 $\mathbf{m}_t$、方差 β_t/α_t 的形式 (3.9)–(3.10)。结果 (3.11) 把对数后验拆成「已知的二次项」+「未知的 $\log q_{t-1}$」，后面所有论证都围绕这两项的相对大小展开。

若第二项也是二次函数，结果立刻是高斯；困难全在第二项。关键问题是：*在后验真正有质量的区域内，第二项能否用简单函数近似?*

第 2 步：尺度论证——为什么可以对 $\log q_{t-1}$ 做一阶泰勒展开。

1. **似然项是一个极窄的「窗口」**。作为 $\mathbf{x}_{t-1}$ 的函数，$\exp\big(-\frac{\alpha_t}{2\beta_t}\|\mathbf{x}_{t-1} - \mathbf{m}_t\|^2\big)$ 是以 $\mathbf{m}_t$ 为中心、每个坐标标准差为 $\sqrt{\beta_t/\alpha_t} \approx \sqrt{\beta_t}$ 的高斯形状（式 (3.10)）。离中心 3 个标准差处它已衰减到 $e^{-3^2/2} = e^{-4.5} \approx 1\%$。因此后验质量集中在 $\mathbf{m}_t$ 附近、半径为 $O(\sqrt{\beta_t})$ 的小邻域内（线性日程下 $\beta_t \le 0.02$，$\sqrt{\beta_t} \le 0.14$，而数据通常归一化到 $[-1, 1]$）。
2. **先验项是光滑的、在「大尺度」上才变化**。对 $t - 1 \ge 1$，

$$q_{t-1}(\mathbf{x}) = \int \mathcal{N}\big(\mathbf{x};\ \sqrt{\bar\alpha_{t-1}}\,\mathbf{x}_0,\ (1 - \bar\alpha_{t-1})\mathbf{I}\big)\,q(\mathbf{x}_0)\,\mathrm{d}\mathbf{x}_0 \tag{3.12}$$

是数据分布与高斯核的卷积，因此即便数据是离散像素，q_{t-1} 也处处为正、无穷次可微，$\log q_{t-1}$ 是光滑函数。记 ℓ_{t-1} 为 $\log q_{t-1}$ 的梯度发生明显变化所需的距离（曲率 $\|\nabla^2 \log q_{t-1}\| \sim 1/\ell_{t-1}^2$），它由数据结构与已加噪声共同决定。粗略地说，前 $t-1$ 步累计的噪声已把尺度小于 $\sigma_{t-1} = \sqrt{1-\bar\alpha_{t-1}}$ 的细节抹平，故典型地 ℓ_{t-1} 不小于 σ_{t-1} 的量级。

3. **窗口远小于变化尺度 $\Rightarrow$ 切平面近似成立**。只要 $\sqrt{\beta_t} \ll \ell_{t-1}$，在这个小窗口里光滑函数 $\log q_{t-1}$ 就近似等于它的切平面（一阶泰勒展开）——这和「地球表面在一个足球场范围内可以看作平面」是同一个道理。

展开点取窗口中心 $\mathbf{m}_t$。记 $\boldsymbol{\delta} = \mathbf{x}_{t-1} - \mathbf{m}_t$，$\mathbf{g}_t = \nabla \log q_{t-1}(\mathbf{m}_t)$，$\mathbf{H}_t = \nabla^2 \log q_{t-1}(\mathbf{m}_t)$：

$$\log q_{t-1}(\mathbf{x}_{t-1}) = \log q_{t-1}(\mathbf{m}_t) + \mathbf{g}_t^\top \boldsymbol{\delta} + \tfrac{1}{2}\,\boldsymbol{\delta}^\top \mathbf{H}_t\,\boldsymbol{\delta} + O\big(\|\boldsymbol{\delta}\|^3/\ell_{t-1}^3\big). \tag{3.13}$$

（也可以在 $\mathbf{x}_t$ 处展开：$\|\mathbf{m}_t - \mathbf{x}_t\| = (\alpha_t^{-1/2} - 1)\|\mathbf{x}_t\| \approx \frac{\beta_t}{2}\|\mathbf{x}_t\| = O(\beta_t)$，远小于窗口宽度 $O(\sqrt{\beta_t})$，只给 $\mathbf{g}_t$ 带来 $O(\beta_t/\ell^2)$ 的变化，无关紧要。）

误差量级。窗口内每个坐标 $\delta_i^2 \sim \beta_t$。逐项比较（按每个坐标计）：

项	量级	作用
似然二次项 $\frac{\alpha_t}{2\beta_t}\delta_i^2$	$O(1)$	决定窗口（主导项）
一阶项 $g_i\delta_i$	$O(\sqrt{\beta_t}/\ell)$	平移均值（保留）
二阶项 $\frac{1}{2}\delta_i H_{ii}\delta_i$	$O(\beta_t/\ell^2)$	仍是二次型，只把协方差改变相对 $O(\beta_t/\ell^2)$
三阶及以上	$O(\beta_t^{3/2}/\ell^3)$	唯一真正破坏高斯形状的部分

注意二阶项即使保留也不破坏高斯性：精度矩阵变为 $\frac{\alpha_t}{\beta_t}\mathbf{I} - \mathbf{H}_t$，协方差变为 $\frac{\beta_t}{\alpha_t}\big(\mathbf{I} - \frac{\beta_t}{\alpha_t}\mathbf{H}_t\big)^{-1} = \frac{\beta_t}{\alpha_t}\big(\mathbf{I} + O(\beta_t/\ell^2)\big)$。非高斯性只来自三阶以上的项，当 $\beta_t \to 0$ 时比主导项小 $O(\beta_t^{3/2})$。

> **比值 β_t/σ_{t-1}^2 有多小？** 以线性日程（$\beta_1 = 10^{-4}$ 到 $\beta_T = 0.02$，$T = 1000$）为例，按上面的粗略估计 $\ell_{t-1} \sim \sigma_{t-1}$：$t = 2$ 时约 1.2，$t = 10$ 时约 0.17，$t = 50$ 时约 0.04，$t \geq 100$ 时 ≤ 0.02。也就是说，除最初几步外近似都很好；而最初几步的噪声标准差仅约 0.01–0.03（肉眼不可见），且 $t = 1$ 由单独的解码项 L_0 处理（第四节）。

第 3 步：代入并配方。 保留到一阶，把 (3.13) 代入 (3.11)：

$$\begin{aligned}
\log q(\mathbf{x}_{t-1} \mid \mathbf{x}_t) &\approx -\frac{\alpha_t}{2\beta_t}\|\boldsymbol{\delta}\|^2 + \mathbf{g}_t^\top \boldsymbol{\delta} + \text{const} \\
&= -\frac{\alpha_t}{2\beta_t}\Big(\|\boldsymbol{\delta}\|^2 - \frac{2\beta_t}{\alpha_t}\,\mathbf{g}_t^\top \boldsymbol{\delta}\Big) + \text{const} && \text{（提出二次项系数）} \\
&= -\frac{\alpha_t}{2\beta_t}\Big(\|\boldsymbol{\delta}\|^2 - 2\,\mathbf{c}^\top \boldsymbol{\delta} + \|\mathbf{c}\|^2 - \|\mathbf{c}\|^2\Big) + \text{const}, \quad \mathbf{c} := \frac{\beta_t}{\alpha_t}\mathbf{g}_t && \text{（加减 } \|\mathbf{c}\|^2\text{）} \\
&= -\frac{\alpha_t}{2\beta_t}\Big\|\boldsymbol{\delta} - \frac{\beta_t}{\alpha_t}\,\mathbf{g}_t\Big\|^2 + \underbrace{\frac{\beta_t}{2\alpha_t}\|\mathbf{g}_t\|^2}_{\text{不含}\mathbf{x}_{t-1}} + \text{const}.
\end{aligned} \tag{3.14}$$

（最后一步用 $\|\boldsymbol{\delta}\|^2 - 2\mathbf{c}^\top\boldsymbol{\delta} + \|\mathbf{c}\|^2 = \|\boldsymbol{\delta} - \mathbf{c}\|^2$，多出的 $+\frac{\alpha_t}{2\beta_t}\|\mathbf{c}\|^2 = \frac{\beta_t}{2\alpha_t}\|\mathbf{g}_t\|^2$ 不含 $\mathbf{x}_{t-1}$。）两边取指数，并把 $\frac{\alpha_t}{2\beta_t}$ 写成 $\frac{1}{2(\beta_t/\alpha_t)}$，与 (3.4) 对照：

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t) \;\propto\; \exp\!\Big(-\frac{\|\mathbf{x}_{t-1} - (\mathbf{m}_t + \mathbf{c})\|^2}{2\,(\beta_t/\alpha_t)}\Big),$$

这正是均值 $\mathbf{m}_t + \frac{\beta_t}{\alpha_t}\mathbf{g}_t$、方差 β_t/α_t 的各向同性高斯（归一化常数按 (1a) 的说明自动补齐）：

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t) \approx \mathcal{N}\Big(\mathbf{x}_{t-1};\; \frac{\mathbf{x}_t}{\sqrt{\alpha_t}} + \frac{\beta_t}{\alpha_t}\nabla \log q_{t-1}\Big(\frac{\mathbf{x}_t}{\sqrt{\alpha_t}}\Big),\; \frac{\beta_t}{\alpha_t}\mathbf{I}\Big). \tag{3.15}$$

再只保留 β_t 的一阶量，化简均值：

$$\begin{aligned}\frac{\mathbf{x}_t}{\sqrt{\alpha_t}}+\frac{\beta_t}{\alpha_t}\,\mathbf{g}_t &= \frac{1}{\sqrt{\alpha_t}}\Big(\mathbf{x}_t+\frac{\beta_t}{\sqrt{\alpha_t}}\,\mathbf{g}_t\Big)\\ &= \frac{1}{\sqrt{\alpha_t}}\big(\mathbf{x}_t+\beta_t\,\mathbf{g}_t\big)+O(\beta_t^2) && \Big(\tfrac{1}{\sqrt{\alpha_t}}=1+O(\beta_t)\Big)\\ &= \frac{1}{\sqrt{\alpha_t}}\big(\mathbf{x}_t+\beta_t\,\nabla\log q_t(\mathbf{x}_t)\big)+O(\beta_t^2) && \Big(\mathbf{g}_t=\nabla\log q_t(\mathbf{x}_t)+O(\beta_t)\Big),\end{aligned}\tag{3.16}$$

最后一步用到两处 $O(\beta_t)$ 的差别：展开点 $\mathbf{m}_t$ 与 $\mathbf{x}_t$ 相差 $O(\beta_t)$；q_{t-1} 与 q_t 只差一步小噪声。同理 $\beta_t/\alpha_t=\beta_t+O(\beta_t^2)$。结论：

$$q(\mathbf{x}_{t-1}\mid\mathbf{x}_t)\approx\mathcal{N}\Big(\mathbf{x}_{t-1};\ \frac{1}{\sqrt{\alpha_t}}\big(\mathbf{x}_t+\beta_t\,\nabla_{\mathbf{x}}\log q_t(\mathbf{x}_t)\big),\ \beta_t\mathbf{I}\Big)\qquad(\beta_t\ \text{很小}).\tag{3.17}$$

方差约为 β_t，这也解释了 3.3 节为何可以直接取 $\sigma_t^2=\beta_t$。

为什么这样做？ **直觉：「窄窗口 × 光滑函数 = 稍微倾斜的窄高斯」**。在窗口内 $q_{t-1}\approx$ 常数 $\times\exp(\mathbf{g}_t^\top\boldsymbol{\delta})$，即一个沿 $\mathbf{g}_t$ 方向的指数「坡」。高斯乘以指数线性函数（统计中称为指数倾斜，exponential tilting）只会把均值沿坡向上移动 $\frac{\beta_t}{\alpha_t}\mathbf{g}_t$，形状和方差都不变。得分 $\mathbf{g}_t$ 指向密度增大的方向，所以反向一步会把样本「往数据更密集的地方推一点」——这正是去噪。图 5 左图给出一维例子：双峰的 q_{t-1}、窄的似然窗口，两者乘积（真实后验，蓝线）与一阶泰勒高斯（红点线）几乎重合，且相对似然中心向右侧峰微移。

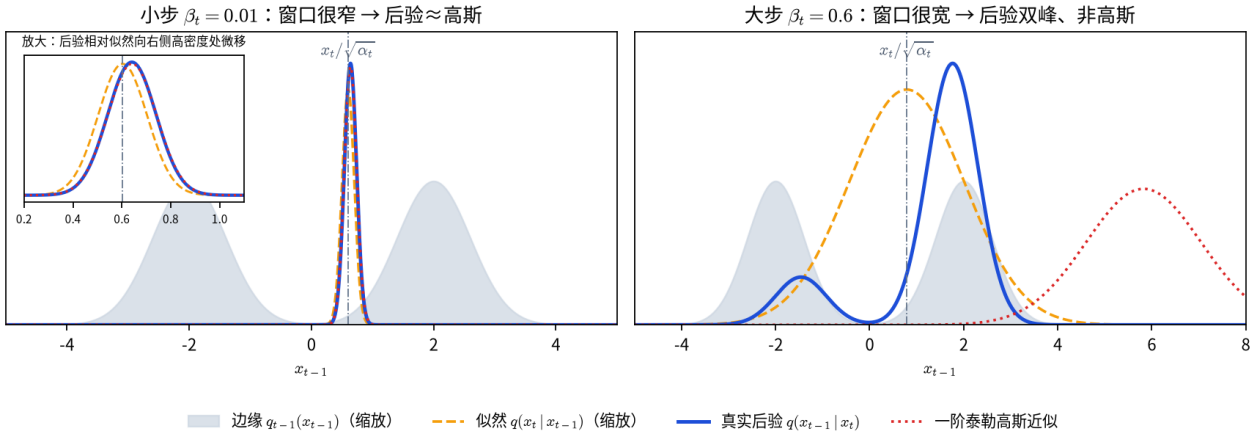


图 5　一维示意：q_{t-1} 为双峰混合（灰），真实后验 $q(x_{t-1}\mid x_t)\propto$ 似然 $\times\,q_{t-1}$（蓝），一阶泰勒高斯近似 (3.15)（红点线）。左：$\beta_t=0.01$，窗口远窄于 q_{t-1} 的变化尺度，近似几乎精确；右：$\beta_t=0.6$，窗口覆盖两个峰，真实后验双峰，高斯近似完全失效。

第 4 步：大步为什么失效。　若 β_t 很大，窗口宽度 $\sqrt{\beta_t}$ 与 ℓ_{t-1} 可比甚至更大：窗口里 $\log q_{t-1}$ 的弯曲、多峰结构都会显现，三阶以上的项不再可忽略，真实后验可以是偏斜的甚至多峰的（图 5 右）。此时用单个高斯建模反向一步会产生系统误差，表现为样本模糊或模式混合。这就是：

- DDPM 采用 $T\approx1000$ 个小步（每步 $\beta_t\le0.02$），让每一步的高斯近似都足够准确；
- 想用很少步数采样时需要别的办法：DDIM、概率流 ODE 等确定性求解器（不再需要逐步的高斯后验假设）、知识蒸馏 / 一致性模型，或像 Denoising Diffusion GAN（Xiao et al., ICLR 2022）那样用可表达多峰的生成器来建模大步的反向转移。

形式化结论。Feller（1949）关于扩散过程的经典结果、以及 Sohl-Dickstein et al.（2015）在扩散生成模型中的论证表明：当步长趋于零时，高斯扩散的反向过程与前向过程具有相同的函数形式（反向也是高斯转移）；上面的泰勒论证正是这一连续极限结论的离散、直观版本。

第 5 步：均值里出现了得分——与 ϵ 形式和 SDE 的联系。 式 (3.17) 的均值含得分 $\nabla \log q_t(\mathbf{x}_t)$。它与噪声的关系可逐行推出：边缘是对 $\mathbf{x}_0$ 的积分 $q_t(\mathbf{x}_t) = \int q(\mathbf{x}_t \mid \mathbf{x}_0)\, q(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0$，对 $\mathbf{x}_t$ 求梯度（梯度可移入积分），并用 $\nabla q = q \nabla \log q$：

$$\nabla q_t(\mathbf{x}_t) = \int \nabla_{\mathbf{x}_t} q(\mathbf{x}_t \mid \mathbf{x}_0)\, q(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0 = \int q(\mathbf{x}_t \mid \mathbf{x}_0)\, q(\mathbf{x}_0)\, \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t \mid \mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0,$$

$$\nabla \log q_t(\mathbf{x}_t) = \frac{\nabla q_t(\mathbf{x}_t)}{q_t(\mathbf{x}_t)} = \int \underbrace{\frac{q(\mathbf{x}_t \mid \mathbf{x}_0)\, q(\mathbf{x}_0)}{q_t(\mathbf{x}_t)}}_{= q(\mathbf{x}_0 \mid \mathbf{x}_t)\ \text{（贝叶斯）}} \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t \mid \mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0.$$

而由 (3.4)，$\log q(\mathbf{x}_t \mid \mathbf{x}_0) = -\frac{\|\mathbf{x}_t - \sqrt{\bar\alpha_t}\mathbf{x}_0\|^2}{2(1-\bar\alpha_t)} + \text{const}$，梯度为 $-\frac{\mathbf{x}_t - \sqrt{\bar\alpha_t}\mathbf{x}_0}{1-\bar\alpha_t} = -\frac{\boldsymbol{\epsilon}}{\sqrt{1-\bar\alpha_t}}$（用 (2.4)）。合起来：

$$\nabla \log q_t(\mathbf{x}_t) = \mathbb{E}_{q(\mathbf{x}_0 \mid \mathbf{x}_t)}\big[\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t \mid \mathbf{x}_0)\big] = -\frac{\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_t]}{\sqrt{1-\bar\alpha_t}}, \tag{3.18}$$

其中用到了第六节式 (6.4) 的条件得分 $-\boldsymbol{\epsilon}/\sqrt{1-\bar\alpha_t}$。代入 (3.17)：

$$\text{均值} \approx \frac{1}{\sqrt{\alpha_t}}\Big(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar\alpha_t}}\, \mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_t]\Big), \tag{3.19}$$

与 3.5 节的噪声参数化 (3.43) 形式完全一致，只需 $\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \approx \mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_t]$——而这恰是简化损失 L_{simple}（均方误差）的最优解。从「小步高斯近似」与从「贝叶斯精确后验 + 对 $\mathbf{x}_0$ 取平均」两条路得到同一个答案。

同样，第六节 VP-SDE (6.3) 的反向 SDE (6.2) 以步长 1（离散时间单位，$\beta(t)\,\mathrm{d}t \to \beta_t$）做一步 Euler–Maruyama：

$$\mathbf{x}_{t-1} = \mathbf{x}_t + \Big(\tfrac{1}{2}\beta_t\, \mathbf{x}_t + \beta_t\, \nabla \log q_t(\mathbf{x}_t)\Big) + \sqrt{\beta_t}\, \mathbf{z} \approx \frac{1}{\sqrt{\alpha_t}}\big(\mathbf{x}_t + \beta_t \nabla \log q_t(\mathbf{x}_t)\big) + \sqrt{\beta_t}\, \mathbf{z}, \tag{3.20}$$

（用到 $1 + \frac{1}{2}\beta_t = \alpha_t^{-1/2} + O(\beta_t^2)$），恰好就是从 (3.17) 中采样。离散的「小步高斯」与连续的「反向 SDE」是同一件事。

3.3 可学习的反向模型

于是用参数化高斯族去拟合反向链：

$$p_\theta(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^{T} p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t), \tag{3.21}$$

$$p(\mathbf{x}_T) = \mathcal{N}(\mathbf{x}_T;\ \mathbf{0},\ \mathbf{I}), \tag{3.22}$$

$$p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t) = \mathcal{N}\big(\mathbf{x}_{t-1};\ \boldsymbol{\mu}_\theta(\mathbf{x}_t, t),\ \sigma_t^2 \mathbf{I}\big)\,. \tag{3.23}$$

一般形式中协方差可写为 $\boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t)$；DDPM 将其固定为与时间相关的各向同性常数 $\sigma_t^2\mathbf{I}$（取 $\sigma_t^2 = \beta_t$ 或 $\sigma_t^2 = \tilde\beta_t$），只学习均值 $\boldsymbol{\mu}_\theta$。

为什么这样做？ 为什么方差可以固定为 β_t 或 $\tilde\beta_t$？ Ho et al.（2020）指出这两个取值分别是反向方差的两个极端：若 $\mathbf{x}_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，最优方差是 β_t；若 $\mathbf{x}_0$ 是一个确定的点，最优方差是 $\tilde\beta_t$（下文式 (3.37)）。真实数据介于两者之间，而 $\tilde\beta_t \le \beta_t$ 且当 T 很大时两者在绝大多数 t 上几乎相等，实验上样本质量相近。固定方差还有两个好处：(i) KL 散度退化为纯粹的均值平方误差（见 4.2 节），训练目标更简单、更稳定；(ii) Ho et al. 报告直接学习对角方差会导致训练不稳定、样本更差（后续 Nichol & Dhariwal 2021 通过在 β_t 与 $\tilde\beta_t$ 之间插值学习方差改进了对数似然）。

3.4 从贝叶斯出发：推导 $q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)$

下面一步一步推导这个「标准答案」后验。所有向量运算都是逐坐标独立的（协方差均为 $\cdot\,\mathbf{I}$），记 $\|\mathbf{v}\|^2 = \mathbf{v}^\top \mathbf{v}$。

第 1 步：贝叶斯公式。 在条件 $\mathbf{x}_0$ 下，对 $\mathbf{x}_{t-1}$ 与 $\mathbf{x}_t$ 应用贝叶斯公式：

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) = \frac{q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0)\, q(\mathbf{x}_{t-1} \mid \mathbf{x}_0)}{q(\mathbf{x}_t \mid \mathbf{x}_0)}. \tag{3.24}$$

第 2 步：马尔可夫性。 前向链是马尔可夫的：给定 $\mathbf{x}_{t-1}$ 后，$\mathbf{x}_t$ 与更早的 $\mathbf{x}_0$ 条件独立，因此

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0) = q(\mathbf{x}_t \mid \mathbf{x}_{t-1}) = \mathcal{N}\big(\mathbf{x}_t;\ \sqrt{\alpha_t}\,\mathbf{x}_{t-1},\ \beta_t \mathbf{I}\big)\,. \tag{3.25}$$

> **为什么这样做？ 为什么要用马尔可夫性？** 贝叶斯公式里的似然项原本是 $q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0)$，我们并没有直接定义它；马尔可夫性把它化成了我们定义过的单步转移 (2.1)。式 (3.24) 的另外两项则正是闭式边缘 (2.5)（分别取 $t-1$ 与 t）。于是右边三项全部已知且都是高斯。

第 3 步：写出三个高斯密度。 利用 $\mathcal{N}(\mathbf{x}; \mathbf{m}, s\mathbf{I}) \propto \exp\!\big(-\tfrac{1}{2}\tfrac{\|\mathbf{x}-\mathbf{m}\|^2}{s}\big)$（即式 (3.4)，3.2 节 (1b) 已推导）：

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}) \propto \exp\!\Big(-\frac{1}{2}\,\frac{\|\mathbf{x}_t - \sqrt{\alpha_t}\,\mathbf{x}_{t-1}\|^2}{\beta_t}\Big), \tag{3.26}$$

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_0) \propto \exp\!\Big(-\frac{1}{2}\,\frac{\|\mathbf{x}_{t-1} - \sqrt{\bar\alpha_{t-1}}\,\mathbf{x}_0\|^2}{1-\bar\alpha_{t-1}}\Big), \tag{3.27}$$

$$q(\mathbf{x}_t \mid \mathbf{x}_0) \propto \exp\!\Big(-\frac{1}{2}\,\frac{\|\mathbf{x}_t - \sqrt{\bar\alpha_t}\,\mathbf{x}_0\|^2}{1-\bar\alpha_t}\Big). \tag{3.28}$$

（三式都由各向同性高斯密度 (3.4) 得到；省略的系数 $(2\pi\beta_t)^{-d/2}$、$(2\pi(1-\bar\alpha_{t-1}))^{-d/2}$、$(2\pi(1-\bar\alpha_t))^{-d/2}$ 都不含 $\mathbf{x}_{t-1}$。）代入 (3.24)：分子两个指数相乘 = 指数相加；除以分母 $\exp(-\frac{1}{2}Q)$ 等于乘以 $\exp(+\frac{1}{2}Q)$，所以分母的平方项在方括号里带**负号**。把所有与 $\mathbf{x}_{t-1}$ 无关的归一化常数吸收进比例号：

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) \propto \exp\!\Big(-\frac{1}{2}\Big[\frac{\|\mathbf{x}_t - \sqrt{\alpha_t}\,\mathbf{x}_{t-1}\|^2}{\beta_t} + \frac{\|\mathbf{x}_{t-1} - \sqrt{\bar\alpha_{t-1}}\,\mathbf{x}_0\|^2}{1-\bar\alpha_{t-1}} - \frac{\|\mathbf{x}_t - \sqrt{\bar\alpha_t}\,\mathbf{x}_0\|^2}{1-\bar\alpha_t}\Big]\Big). \tag{3.29}$$

注意：这里的变量是 $\mathbf{x}_{t-1}$；$\mathbf{x}_t$ 与 $\mathbf{x}_0$ 都是给定的常量。

第 4 步：展开指数。 逐项展开平方（$\|\mathbf{a}-\mathbf{b}\|^2 = \|\mathbf{a}\|^2 - 2\mathbf{a}^\top\mathbf{b} + \|\mathbf{b}\|^2$）：

$$\frac{\|\mathbf{x}_t - \sqrt{\alpha_t}\,\mathbf{x}_{t-1}\|^2}{\beta_t} = \frac{\|\mathbf{x}_t\|^2}{\beta_t} - \frac{2\sqrt{\alpha_t}}{\beta_t}\,\mathbf{x}_t^\top\mathbf{x}_{t-1} + \frac{\alpha_t}{\beta_t}\,\|\mathbf{x}_{t-1}\|^2, \tag{3.30}$$

$$\frac{\|\mathbf{x}_{t-1} - \sqrt{\bar\alpha_{t-1}}\,\mathbf{x}_0\|^2}{1-\bar\alpha_{t-1}} = \frac{\|\mathbf{x}_{t-1}\|^2}{1-\bar\alpha_{t-1}} - \frac{2\sqrt{\bar\alpha_{t-1}}}{1-\bar\alpha_{t-1}}\,\mathbf{x}_0^\top\mathbf{x}_{t-1} + \frac{\bar\alpha_{t-1}\|\mathbf{x}_0\|^2}{1-\bar\alpha_{t-1}}, \tag{3.31}$$

$$\frac{\|\mathbf{x}_t - \sqrt{\bar\alpha_t}\,\mathbf{x}_0\|^2}{1-\bar\alpha_t} = C_1(\mathbf{x}_t, \mathbf{x}_0) \qquad (\text{与 } \mathbf{x}_{t-1} \text{ 无关})\,. \tag{3.32}$$

第 5 步：按 $\mathbf{x}_{t-1}$ 的二次项、一次项、常数项归类。 方括号内整体等于

$$\underbrace{\Big(\frac{\alpha_t}{\beta_t} + \frac{1}{1-\bar\alpha_{t-1}}\Big)}_{=:\,A_t}\|\mathbf{x}_{t-1}\|^2 \;-\; 2\,\underbrace{\Big(\frac{\sqrt{\alpha_t}}{\beta_t}\,\mathbf{x}_t + \frac{\sqrt{\bar\alpha_{t-1}}}{1-\bar\alpha_{t-1}}\,\mathbf{x}_0\Big)}_{=:\,\mathbf{b}_t}{}^{\top}\mathbf{x}_{t-1} \;+\; C_2(\mathbf{x}_t, \mathbf{x}_0), \tag{3.33}$$

其中 $C_2 = \frac{\|\mathbf{x}_t\|^2}{\beta_t} + \frac{\bar\alpha_{t-1}\|\mathbf{x}_0\|^2}{1-\bar\alpha_{t-1}} - C_1$ 不含 $\mathbf{x}_{t-1}$。

第 6 步：配方。 对任意 $A > 0$，

$$A\|\mathbf{x}\|^2 - 2\mathbf{b}^\top\mathbf{x} = A\,\Big\|\mathbf{x} - \frac{\mathbf{b}}{A}\Big\|^2 - \frac{\|\mathbf{b}\|^2}{A} = \frac{\|\mathbf{x} - \mathbf{b}/A\|^2}{1/A} + \text{常数}. \tag{3.34}$$

因此 $q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) \propto \exp\!\big(-\tfrac{1}{2}\,\|\mathbf{x}_{t-1} - \mathbf{b}_t/A_t\|^2/(1/A_t)\big)$，它是高斯，**方差** $= 1/A_t$，**均值** $= \mathbf{b}_t/A_t$：

$$\tilde\beta_t = \frac{1}{A_t}, \qquad \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\mathbf{b}_t}{A_t} = \tilde\beta_t\,\mathbf{b}_t. \tag{3.35}$$

为什么这样做？ **为什么只看 $\mathbf{x}_{t-1}$ 的二次项和一次项？** 高斯的对数密度是变量的二次函数：$-\frac{1}{2s}\|\mathbf{x}-\mathbf{m}\|^2 = -\frac{1}{2}\big(\frac{1}{s}\|\mathbf{x}\|^2 - \frac{2}{s}\mathbf{m}^\top\mathbf{x}\big)$ + 常数。二次项系数给出精度 $1/s$，一次项系数给出 $\mathbf{m}/s$；常数项只影响归一化，最后会被自动补齐。这样就不必去算繁琐的归一化常数。

第 7 步：化简方差 $\tilde{\beta}_t$。 通分并利用 $\beta_t = 1-\alpha_t$、$\alpha_t\bar{\alpha}_{t-1} = \bar{\alpha}_t$：

$$\begin{aligned}\frac{1}{\tilde{\beta}_t} = A_t &= \frac{\alpha_t}{\beta_t} + \frac{1}{1-\bar{\alpha}_{t-1}} = \frac{\alpha_t(1-\bar{\alpha}_{t-1})+\beta_t}{\beta_t(1-\bar{\alpha}_{t-1})} \\ &= \frac{\alpha_t - \alpha_t\bar{\alpha}_{t-1} + 1 - \alpha_t}{\beta_t(1-\bar{\alpha}_{t-1})} = \frac{1-\bar{\alpha}_t}{\beta_t(1-\bar{\alpha}_{t-1})},\end{aligned} \tag{3.36}$$

所以

$$\tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\,\beta_t. \tag{3.37}$$

第 8 步：化简均值 $\tilde{\boldsymbol{\mu}}_t$。 由 (3.35)，把 $\tilde{\beta}_t$ 乘进 $\mathbf{b}_t$ 的两项：

$$\begin{aligned}\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t,\mathbf{x}_0) &= \frac{(1-\bar{\alpha}_{t-1})\beta_t}{1-\bar{\alpha}_t}\Big(\frac{\sqrt{\alpha_t}}{\beta_t}\,\mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}}\,\mathbf{x}_0\Big) \\ &= \frac{\sqrt{\alpha_t}\,(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\,\mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\,\beta_t}{1-\bar{\alpha}_t}\,\mathbf{x}_0.\end{aligned} \tag{3.38}$$

整理成结论：

$$q(\mathbf{x}_{t-1}\mid\mathbf{x}_t,\mathbf{x}_0) = \mathcal{N}\Big(\mathbf{x}_{t-1};\ \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t,\mathbf{x}_0),\ \tilde{\beta}_t\mathbf{I}\Big), \tag{3.39}$$

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t,\mathbf{x}_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\,\beta_t}{1-\bar{\alpha}_t}\,\mathbf{x}_0 + \frac{\sqrt{\alpha_t}\,(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\,\mathbf{x}_t. \tag{3.40}$$

为什么这样做？ **如何理解这个结果？** (1) $\tilde{\boldsymbol{\mu}}_t$ 是 $\mathbf{x}_0$（「干净图像在哪」）与 $\mathbf{x}_t$（「当前所在位置」）的加权组合：$\mathbf{x}_0$ 的权重随 β_t 增大，$\mathbf{x}_t$ 的权重随 $1-\bar{\alpha}_{t-1}$ 增大。(2) 两个高斯「证据」（来自 $\mathbf{x}_t$ 的似然、来自 $\mathbf{x}_0$ 的先验）相乘，精度相加：$1/\tilde{\beta}_t = \alpha_t/\beta_t + 1/(1-\bar{\alpha}_{t-1})$，所以 $\tilde{\beta}_t$ 比任何单方证据的方差都小，且 $\tilde{\beta}_t \le \beta_t$。(3) **自检：** $t=1$ 时 $\bar{\alpha}_0 = 1$，得 $\tilde{\beta}_1 = 0$、$\tilde{\boldsymbol{\mu}}_1 = \mathbf{x}_0$——已知 $\mathbf{x}_0$ 时，「上一步」就是 $\mathbf{x}_0$ 本身，完全合理。

3.5 把 $\tilde{\mu}_t$ 改写成噪声 ϵ 的形式

采样时 $\mathbf{x}_0$ 是未知的，所以 (3.40) 不能直接用。但由闭式 (2.4)（即重参数化，见 2.4 节用法 (3c)-(iii)），给定 $\mathbf{x}_t$ 时 $\mathbf{x}_0$ 与 $\boldsymbol{\epsilon}$ 一一对应：

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon} \quad\Longleftrightarrow\quad \mathbf{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}}\Big(\mathbf{x}_t - \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}\Big). \tag{3.41}$$

把 (3.41) 代入 (3.40)，并注意 $\sqrt{\bar{\alpha}_{t-1}}/\sqrt{\bar{\alpha}_t} = 1/\sqrt{\alpha_t}$：

$$\begin{aligned}\tilde{\boldsymbol{\mu}}_t &= \frac{\sqrt{\bar{\alpha}_{t-1}}\,\beta_t}{1-\bar{\alpha}_t}\cdot\frac{1}{\sqrt{\bar{\alpha}_t}}\Big(\mathbf{x}_t - \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}\Big) + \frac{\sqrt{\alpha_t}\,(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\,\mathbf{x}_t \\ &= \frac{\beta_t}{\sqrt{\alpha_t}\,(1-\bar{\alpha}_t)}\,\mathbf{x}_t - \frac{\beta_t\sqrt{1-\bar{\alpha}_t}}{\sqrt{\alpha_t}\,(1-\bar{\alpha}_t)}\,\boldsymbol{\epsilon} + \frac{\sqrt{\alpha_t}\,(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\,\mathbf{x}_t \\ &= \frac{\beta_t + \alpha_t(1-\bar{\alpha}_{t-1})}{\sqrt{\alpha_t}\,(1-\bar{\alpha}_t)}\,\mathbf{x}_t - \frac{\beta_t}{\sqrt{\alpha_t}\,\sqrt{1-\bar{\alpha}_t}}\,\boldsymbol{\epsilon} \qquad \big(\text{第三项上下同乘}\sqrt{\alpha_t}\big) \\ &= \frac{1-\bar{\alpha}_t}{\sqrt{\alpha_t}\,(1-\bar{\alpha}_t)}\,\mathbf{x}_t - \frac{\beta_t}{\sqrt{\alpha_t}\,\sqrt{1-\bar{\alpha}_t}}\,\boldsymbol{\epsilon} \qquad \big(\text{分子同 (3.36)：}\ \beta_t+\alpha_t-\bar{\alpha}_t = 1-\bar{\alpha}_t\big)\end{aligned}$$

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{1}{\sqrt{\alpha_t}}\left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}\right), \qquad \boldsymbol{\epsilon} = \frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0}{\sqrt{1-\bar{\alpha}_t}}. \tag{3.42}$$

现在「理想均值」里唯一未知的是 $\mathbf{x}_t$ 中所含的噪声 $\boldsymbol{\epsilon}$。用网络 $\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)$ 预测它，就得到可学习的均值：

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}}\left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\right). \tag{3.43}$$

网络的任务变成：看见带噪样本 $\mathbf{x}_t$ 与时间 t，输出「当初加进去的那份噪声」$\boldsymbol{\epsilon}$ 的估计。

3.6 为什么预测噪声 ϵ，而不是 x_0 或 $\tilde{\mu}_t$

为什么这样做?

1. **三者在数学上等价**。给定 $(\mathbf{x}_t, t)$，由 (3.41) 与 (3.42)，$\boldsymbol{\epsilon}$、$\mathbf{x}_0$、$\tilde{\boldsymbol{\mu}}_t$ 之间是可逆的仿射变换：$\hat{\mathbf{x}}_0 = (\mathbf{x}_t - \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}_\theta)/\sqrt{\bar{\alpha}_t}$。所以选哪个只是重参数化，不改变模型表达能力；差别在于优化难度。
2. **尺度统一、数值稳定**。目标 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 对所有 t 都是单位方差，网络输出的尺度不随 t 变化。若预测 $\tilde{\boldsymbol{\mu}}_t$：小 t 时 $\tilde{\boldsymbol{\mu}}_t \approx \mathbf{x}_t$，网络要输出「几乎恒等 + 极小修正」，修正量淹没在大信号里；若预测 $\mathbf{x}_0$：大 t 时几乎看不到信号，再通过 $1/\sqrt{\bar{\alpha}_t}$ 等系数传播时误差会被放大。
3. **类似残差学习**。式 (3.43) 中 $\boldsymbol{\mu}_\theta = \frac{1}{\sqrt{\alpha_t}}\mathbf{x}_t -$ (小修正)，网络只负责「修正量」部分，这与 ResNet 学残差的思路一致。
4. **与得分直接对应**。$\nabla_{\mathbf{x}_t}\log q(\mathbf{x}_t \mid \mathbf{x}_0) = -\boldsymbol{\epsilon}/\sqrt{1-\bar{\alpha}_t}$（第六节式 (6.4)），预测噪声就是在估计（缩放后的）得分，训练目标即多噪声尺度下的去噪得分匹配。
5. **实验结论**。Ho et al.（2020，表 2）比较过预测 $\tilde{\boldsymbol{\mu}}$ 与预测 $\boldsymbol{\epsilon}$：$\boldsymbol{\epsilon}$ 预测配合简化损失得到了最好的 FID。

四、训练目标：从变分下界到简化 MSE

4.1 极大似然与 ELBO

我们希望最大化 $\mathbb{E}_{q(\mathbf{x}_0)}[\log p_\theta(\mathbf{x}_0)]$。引入潜变量 $\mathbf{x}_{1:T}$ 后，由 Jensen 不等式得到变分下界（ELBO）；习惯上最小化其相反数 L_{VLB}（负对数似然的上界）：

$$-\log p_\theta(\mathbf{x}_0) \;\le\; \mathbb{E}_{q(\mathbf{x}_{1:T}\mid\mathbf{x}_0)}\left[-\log\frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}\mid\mathbf{x}_0)}\right] \;=:\; L_{\mathrm{VLB}}. \tag{4.1}$$

为什么这样做? **为什么不直接最大化** $\log p_\theta(\mathbf{x}_0)$? $p_\theta(\mathbf{x}_0) = \int p_\theta(\mathbf{x}_{0:T})\,\mathrm{d}\mathbf{x}_{1:T}$ 是对 T 个高维变量的积分，无法计算。借助前向过程 $q(\mathbf{x}_{1:T}\mid\mathbf{x}_0)$ 作为「变分分布」（且它固定、易采样），就能把对数似然换成可蒙特卡洛估计的上界 L_{VLB}；压低上界即间接提高似然。

分解推导。由 (2.2) 与 (3.21)，

$$L_{\mathrm{VLB}} = \mathbb{E}_q\Big[-\log p(\mathbf{x}_T) - \sum_{t=2}^{T}\log\frac{p_\theta(\mathbf{x}_{t-1}\mid\mathbf{x}_t)}{q(\mathbf{x}_t\mid\mathbf{x}_{t-1})} - \log\frac{p_\theta(\mathbf{x}_0\mid\mathbf{x}_1)}{q(\mathbf{x}_1\mid\mathbf{x}_0)}\Big]. \tag{4.2}$$

关键一步：对 $t \ge 2$ 用马尔可夫性和贝叶斯公式 (3.24)，把前向转移「翻转」成后验：

$$q(\mathbf{x}_t\mid\mathbf{x}_{t-1}) = q(\mathbf{x}_t\mid\mathbf{x}_{t-1},\mathbf{x}_0) = \frac{q(\mathbf{x}_{t-1}\mid\mathbf{x}_t,\mathbf{x}_0)\,q(\mathbf{x}_t\mid\mathbf{x}_0)}{q(\mathbf{x}_{t-1}\mid\mathbf{x}_0)}. \tag{4.3}$$

代入后，$\sum_{t=2}^{T}\log\frac{q(\mathbf{x}_t|\mathbf{x}_0)}{q(\mathbf{x}_{t-1}|\mathbf{x}_0)} = \log\frac{q(\mathbf{x}_T|\mathbf{x}_0)}{q(\mathbf{x}_1|\mathbf{x}_0)}$ 逐项相消（望远镜求和），其中 $q(\mathbf{x}_1\mid\mathbf{x}_0)$ 与最后一项中的 $q(\mathbf{x}_1\mid\mathbf{x}_0)$ 抵消，剩下

$$L_{\mathrm{VLB}} = \mathbb{E}_q\Big[\log\frac{q(\mathbf{x}_T\mid\mathbf{x}_0)}{p(\mathbf{x}_T)} + \sum_{t=2}^{T}\log\frac{q(\mathbf{x}_{t-1}\mid\mathbf{x}_t,\mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1}\mid\mathbf{x}_t)} - \log p_\theta(\mathbf{x}_0\mid\mathbf{x}_1)\Big], \tag{4.4}$$

每个对数比在期望下就是一个 KL 散度，得到常见分解（符号随文献略有出入）：

$$L_{\mathrm{VLB}} = L_T + \sum_{t=2}^{T} L_{t-1} + L_0, \tag{4.5}$$

$$L_T = \mathbb{E}_q[D_{\mathrm{KL}}(q(\mathbf{x}_T \mid \mathbf{x}_0) \,\|\, p(\mathbf{x}_T))] \qquad \text{（前向末端 vs 标准正态先验，与 } \theta \text{ 无关且很小）}$$

$$L_{t-1} = \mathbb{E}_q[D_{\mathrm{KL}}(q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) \,\|\, p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t))]$$

$$L_0 = -\mathbb{E}_q[\log p_\theta(\mathbf{x}_0 \mid \mathbf{x}_1)] \qquad \text{（离散像素时常用离散解码器似然）}$$

为什么这样做？ 为什么要让 $p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t)$ 去匹配后验 $q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)$？ 这不是人为的选择，而是 ELBO 分解自动给出的：最小化 L_{VLB} 就是最小化每个 L_{t-1} 中的 KL。之所以出现「条件在 $\mathbf{x}_0$ 上」的后验，是因为上面翻转前向转移时引入了 $\mathbf{x}_0$，而这正好让比较对象变成可解析计算的高斯（3.4 节）。
但 p_θ 看不到 $\mathbf{x}_0$，怎么匹配？ 对固定的 $\mathbf{x}_t$，不同的 $\mathbf{x}_0$ 给出不同的 $\tilde{\boldsymbol{\mu}}_t$；网络只能输出一个 $\boldsymbol{\mu}_\theta(\mathbf{x}_t, t)$。平方误差回归的最优解是条件期望：$\boldsymbol{\mu}_\theta^\star(\mathbf{x}_t, t) = \mathbb{E}_{q(\mathbf{x}_0 \mid \mathbf{x}_t)}[\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0)]$，这恰好是真实反向转移 $q(\mathbf{x}_{t-1} \mid \mathbf{x}_t)$ 的均值。所以「对带噪标签做回归」最终学到的就是那个我们算不出来的真实反向均值。

4.2 高斯 KL 化为均值匹配

因为 $q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)$ 与 $p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t)$ 都是各向同性高斯，且协方差固定为 $\tilde{\beta}_t \mathbf{I}$ 与 $\sigma_t^2 \mathbf{I}$，利用两个高斯的 KL 公式 $D_{\mathrm{KL}}\big(\mathcal{N}(\mathbf{m}_1, s_1\mathbf{I}) \,\|\, \mathcal{N}(\mathbf{m}_2, s_2\mathbf{I})\big) = \frac{\|\mathbf{m}_1 - \mathbf{m}_2\|^2}{2s_2} + \frac{d}{2}\big(\frac{s_1}{s_2} - 1 - \log\frac{s_1}{s_2}\big)$（$d$ 为维数），后一项与 θ 无关，故 KL 散度除去常数 C 外，就是两均值之差的加权平方：

$$L_{t-1} = \mathbb{E}_q\left[\frac{1}{2\sigma_t^2}\left\|\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_\theta(\mathbf{x}_t, t)\right\|^2\right] + C. \tag{4.6}$$

4.3 换成 ϵ 参数化后的简化目标

把 $\boldsymbol{\mu}_\theta$ 用 (3.43) 参数化，并做重参数化 $\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}$（2.4 节），由 (3.42) 与 (3.43)，两均值中 $\mathbf{x}_t$ 项相同、直接相消：

$$\tilde{\boldsymbol{\mu}}_t - \boldsymbol{\mu}_\theta = \frac{1}{\sqrt{\alpha_t}} \cdot \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\big(\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) - \boldsymbol{\epsilon}\big), \qquad \frac{\|\tilde{\boldsymbol{\mu}}_t - \boldsymbol{\mu}_\theta\|^2}{2\sigma_t^2} = \frac{\beta_t^2}{2\sigma_t^2\,\alpha_t\,(1-\bar{\alpha}_t)}\,\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta\|^2. \tag{4.7}$$

于是均值匹配等价于加权的噪声匹配：

$$L_{t-1} - C = \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}}\left[\frac{\beta_t^2}{2\sigma_t^2\,\alpha_t\,(1-\bar{\alpha}_t)}\left\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta\big(\sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon},\ t\big)\right\|^2\right]. \tag{4.8}$$

DDPM 进一步丢掉随 t 变化的权重，得到实践中极其好用的简化损失：

$$L_{\mathrm{simple}}(\theta) = \mathbb{E}_{t, \mathbf{x}_0, \boldsymbol{\epsilon}}\left[\left\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta\big(\sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon},\ t\big)\right\|^2\right], \tag{4.9}$$

$$t \sim \mathrm{Uniform}\{1, \dots, T\}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \qquad \mathbf{x}_0 \sim q(\mathbf{x}_0)\ \text{（数据）}.$$

为什么这样做？ 为什么可以丢掉权重 $\lambda_t = \frac{\beta_t^2}{2\sigma_t^2\alpha_t(1-\bar{\alpha}_t)}$？ (1) 取 $\sigma_t^2 = \beta_t$ 时 $\lambda_t = \frac{\beta_t}{2\alpha_t(1-\bar{\alpha}_t)}$：$t=1$ 时 $1-\bar{\alpha}_1 = \beta_1$，$\lambda_1 \approx \frac{1}{2}$；$t$ 较大时 $1-\bar{\alpha}_t \approx 1$，$\lambda_t \approx \beta_t/2 \sim 10^{-2}$。也就是说 ELBO 权重偏重小 t（几乎没有噪声、本来就容易的去噪）。(2) 去掉权重相当于相对提高大 t 的权重，让网络把容量用在更难的去噪任务上；Ho et al. 实验中这显著提升了样本质量（FID），代价是对数似然略差。(3) 去权重后各项的数值尺度一致（都是单位方差噪声的 MSE），梯度更平稳，实现也最简单。(4) 它仍是「各噪声水平上的去噪得分匹配之和」，只是换了一种加权，因此依然是合理的训练目标。

推导链小结： 似然 → ELBO → 逐步 KL → 高斯均值匹配 → ϵ 参数化 → （可选）去权重得到 L_{simple}。简化损失不等于精确的 L_{VLB}，但在图像生成上往往更稳、样本质量更好，因而成为事实标准。

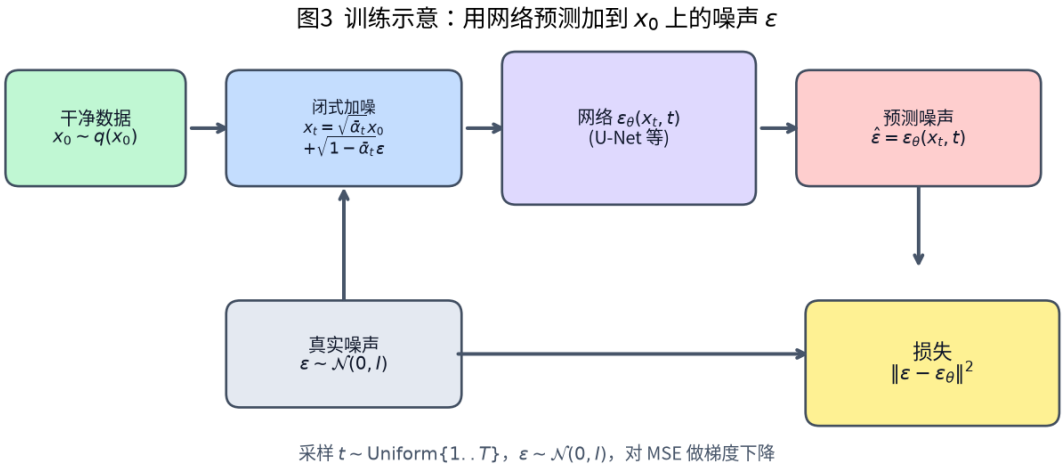


图 3　训练流程图：闭式构造 $\mathbf{x}_t$，网络预测 ϵ，对 MSE 反向传播

4.4　训练算法（伪代码）

算法 1 DDPM 训练（Ho et al., 2020, Algorithm 1）

repeat
　$\mathbf{x}_0 \sim q(\mathbf{x}_0)$　　▷ 从训练集采样
　$t \sim \text{Uniform}\{1, \dots, T\}$
　$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
　$\mathbf{x}_t \leftarrow \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}$　　▷ 重参数化闭式加噪，式 (2.4)
　对 $\nabla_\theta \left\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\right\|^2$ 做一步梯度下降
until 收敛

五、采样算法（DDPM）

训练完成后，生成新样本不需要 $\mathbf{x}_0$，只需从先验噪声出发迭代应用学习到的反向转移 (3.23)。

算法 2 DDPM 祖先采样（ancestral sampling）

$\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
for $t = T, T-1, \dots, 1$ **do**
　$\hat{\boldsymbol{\epsilon}} \leftarrow \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)$
　$\boldsymbol{\mu} \leftarrow \dfrac{1}{\sqrt{\alpha_t}}\left(\mathbf{x}_t - \dfrac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\,\hat{\boldsymbol{\epsilon}}\right)$　　▷ 式 (3.43)
　if $t > 1$ **then**
　　$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
　else
　　$\mathbf{z} \leftarrow \mathbf{0}$
　end if
　$\mathbf{x}_{t-1} \leftarrow \boldsymbol{\mu} + \sigma_t\,\mathbf{z}$　　▷ 重参数化采样；$\sigma_t = \sqrt{\beta_t}$ 或 $\sqrt{\tilde{\beta}_t}$
end for
return $\mathbf{x}_0$　　▷ 图像任务中常再裁剪/量化到有效像素范围

直观理解每一步：网络先估计「当前噪声成分」，再按公式从 $\mathbf{x}_t$ 中减掉相应比例，并注入适量随机性 $\sigma_t\mathbf{z}$，以免塌缩成单一模式。若直接令 $\sigma_t = 0$，得到的是一种确定性的去噪迭代；严格的确定性采样（如 DDIM、

概率流 ODE）还需相应修改均值更新式，属于相关但不同的算法族。

> **为什么这样做？** **为什么每步要加随机噪声 $\sigma_t\mathbf{z}$？** 模型定义的 $p_\theta(\mathbf{x}_{t-1}\mid\mathbf{x}_t)$ 本身就是一个有方差 σ_t^2 的高斯，祖先采样就是严格按这个分布逐步抽样；只取均值相当于每一步都取「最可能值」，会使样本偏向平均、过于平滑，且与训练时假设的分布不一致。**为什么最后一步 $t=1$ 不加噪声？** $\boldsymbol{\mu}_\theta(\mathbf{x}_1,1)$ 已是对干净数据的最终估计，此时再加噪声只会把输出弄脏（且 $\tilde\beta_1=0$）。**为什么必须按 $t=T\to1$ 逐步走？** 每个 $p_\theta(\mathbf{x}_{t-1}\mid\mathbf{x}_t)$ 只在「小步」下才近似为高斯（3.2 节），一次跳很多步会破坏这个假设——这也是加速采样需要专门设计（如 DDIM）的原因。

计算代价：标准 DDPM 需 T 次网络前向（如 $T=1000$），较慢；后续工作提出 DDIM、蒸馏、一致性模型等加速方法，但数学骨架仍建立在同一前向/反向框架上。

六、与 Score Matching / 连续时间 SDE 的直觉桥接

离散 DDPM 可以看作连续时间随机微分方程（SDE）的一种离散化。Song 等人（2021）把前向过程写成 Itô SDE：

$$\mathrm{d}\mathbf{x}=\mathbf{f}(\mathbf{x},t)\,\mathrm{d}t+g(t)\,\mathrm{d}\mathbf{w}, \tag{6.1}$$

其中 $\mathbf{w}$ 为标准维纳过程。对应的反向时间 SDE（Anderson, 1982）为：

$$\mathrm{d}\mathbf{x}=\big[\mathbf{f}(\mathbf{x},t)-g(t)^2\,\nabla_{\mathbf{x}}\log p_t(\mathbf{x})\big]\,\mathrm{d}t+g(t)\,\mathrm{d}\bar{\mathbf{w}}, \tag{6.2}$$

这里时间从终点倒流回 0（$\mathrm{d}t$ 为负的无穷小时间步），$\bar{\mathbf{w}}$ 为反向时间的维纳过程。DDPM 对应的是 VP-SDE（variance preserving）：

$$\mathrm{d}\mathbf{x}=-\tfrac{1}{2}\beta(t)\,\mathbf{x}\,\mathrm{d}t+\sqrt{\beta(t)}\,\mathrm{d}\mathbf{w}, \tag{6.3}$$

取连续时间 $\tau\in[0,1]$，令 $\beta_i=\beta(i/T)/T$（$i=1,\dots,T$），则离散链 (2.1) 在 $T\to\infty$ 时收敛到 (6.3)。

式 (6.2) 中的 $\nabla_{\mathbf{x}}\log p_t(\mathbf{x})$ 称为得分（score）。若能用网络 $\mathbf{s}_\theta(\mathbf{x},t)\approx\nabla_{\mathbf{x}}\log p_t(\mathbf{x})$，即可数值模拟反向 SDE 来生成样本。由 (2.5) 直接求梯度：

$$\nabla_{\mathbf{x}_t}\log q(\mathbf{x}_t\mid\mathbf{x}_0)=-\frac{\mathbf{x}_t-\sqrt{\bar\alpha_t}\,\mathbf{x}_0}{1-\bar\alpha_t}=-\frac{\boldsymbol{\epsilon}}{\sqrt{1-\bar\alpha_t}}\quad\Longrightarrow\quad\boldsymbol{\epsilon}_\theta(\mathbf{x}_t,t)\approx-\sqrt{1-\bar\alpha_t}\,\mathbf{s}_\theta(\mathbf{x}_t,t). \tag{6.4}$$

（去噪得分匹配保证：以条件得分 $\nabla_{\mathbf{x}_t}\log q(\mathbf{x}_t\mid\mathbf{x}_0)$ 为回归目标的最优解，正是边缘得分 $\nabla_{\mathbf{x}_t}\log q_t(\mathbf{x}_t)$。）

因此：「预测噪声」与「估计得分」是同一枚硬币的两面。离散噪声预测 MSE，在连续时间里对应去噪得分匹配（denoising score matching）目标。VP-SDE 与 DDPM 前向过程尤为接近；VE-SDE（variance exploding，对应 Song & Ermon 2019 的 NCSN）等变体则对应不同噪声日程。本教案只需建立这座桥：学会 DDPM 后，读 Score SDE 文献时不会觉得是两套无关理论。

> **为什么这样做？** **为什么要引入连续时间 SDE 视角？** (1) 统一：DDPM（VP）与 NCSN（VE）只是同一框架下 $\mathbf{f}$、g 的不同选择；(2) 采样更灵活：反向 SDE 可以用任意数值求解器离散化，步数不再绑定训练时的 T；(3) 确定性生成：每个 SDE 都对应一个边缘分布相同的概率流 ODE，可用于快速采样与精确似然计算；(4) 核心只需得分：反向过程中唯一未知的量就是 $\nabla_{\mathbf{x}}\log p_t(\mathbf{x})$，这解释了为什么「学会去噪 = 学会生成」。

七、小结与常见误区

7.1 要点回顾

- 前向 q：固定加噪马尔可夫链；闭式 $\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}$ 是训练与推导的枢纽。
- 重参数化 $\mathbf{z} = \boldsymbol{\mu} + \sigma\boldsymbol{\epsilon}$：独立噪声方差相加得到闭式；在 DDPM 中主要用于一步构造 $\mathbf{x}_t$、提供回归标签 $\boldsymbol{\epsilon}$、在 $\mathbf{x}_0$ 与 $\boldsymbol{\epsilon}$ 间换算。
- 反向 p_θ：学习高斯转移；常用 $\boldsymbol{\epsilon}_\theta$ 参数化均值 $\boldsymbol{\mu}_\theta$。
- 后验 $q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)$：贝叶斯 + 马尔可夫 + 配方，得 $\tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$ 与 $\tilde{\boldsymbol{\mu}}_t = \frac{1}{\sqrt{\alpha_t}}\big(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}\big)$。
- 训练：ELBO $\to$ 逐步 KL $\to$（简化）噪声 MSE；实现极简，效果极强。
- 采样：从 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 迭代去噪；步数与 σ_t 选择影响质量与多样性。
- 统一视角：$\boldsymbol{\epsilon}$ 预测 $\approx$ score 估计；DDPM $\approx$ VP-SDE 的一种离散实现。

7.2 常见误区

误区 A：以为训练时必须逐步模拟 $t = 1, \ldots, T$ 的整条加噪链。
纠正：闭式 (2.4) 采样任意 t 即可；逐步模拟反而更慢且不必要。

误区 B：把 β_t 当成需要网络学习的参数。
纠正：标准 DDPM 中 β 日程是预设的；网络学的是 $\boldsymbol{\epsilon}_\theta$（或等价的均值 / 得分）。

误区 C：认为 L_{simple} 就是精确的负对数似然。
纠正：它是 ELBO 相关目标的去权重 / 简化版本；利于样本质量，但不等于精确似然（甚至不等于 L_{VLB}）。

误区 D：采样时把 σ_t 随意设很大，或干脆去掉随机性却期望相同效果。
纠正：σ_t 影响多样性与清晰度；确定性采样（如 DDIM）是另一族算法，轨迹不同。

误区 E：把「扩散」理解成必须在像素空间、必须用 U-Net。
纠正：框架与表示空间、骨干网络解耦；亦可在潜空间（如 Latent Diffusion）上进行。

误区 F：混淆前向与反向谁在「学习」。
纠正：前向固定；学习发生在反向（或等价的 score 网络）中。

7.3 自学建议

建议顺序：先吃透闭式 $q(\mathbf{x}_t \mid \mathbf{x}_0)$ 与 L_{simple} 的实现（能手写训练循环）$\to$ 再回看 ELBO 分解理解「为何这样训」$\to$ 最后读 Score SDE 统一框架与加速采样。动手时可用一维或二维合成分布（如图 2、图 4）验证：看不见图像也能把数学跑通。

本教案为自学向整理，公式采用通行记法，插图由 matplotlib 生成。
若与原论文符号下标偶有出入，以 Ho et al. (2020) 与 Song et al. (2021) 原文为准。